UNIVERSIDAD · ECCI

SISTEMAS AVANZADOS DE PRODUCCIÓN CON PYTHON

Semana7: Ejecución del proyecto en Notebook

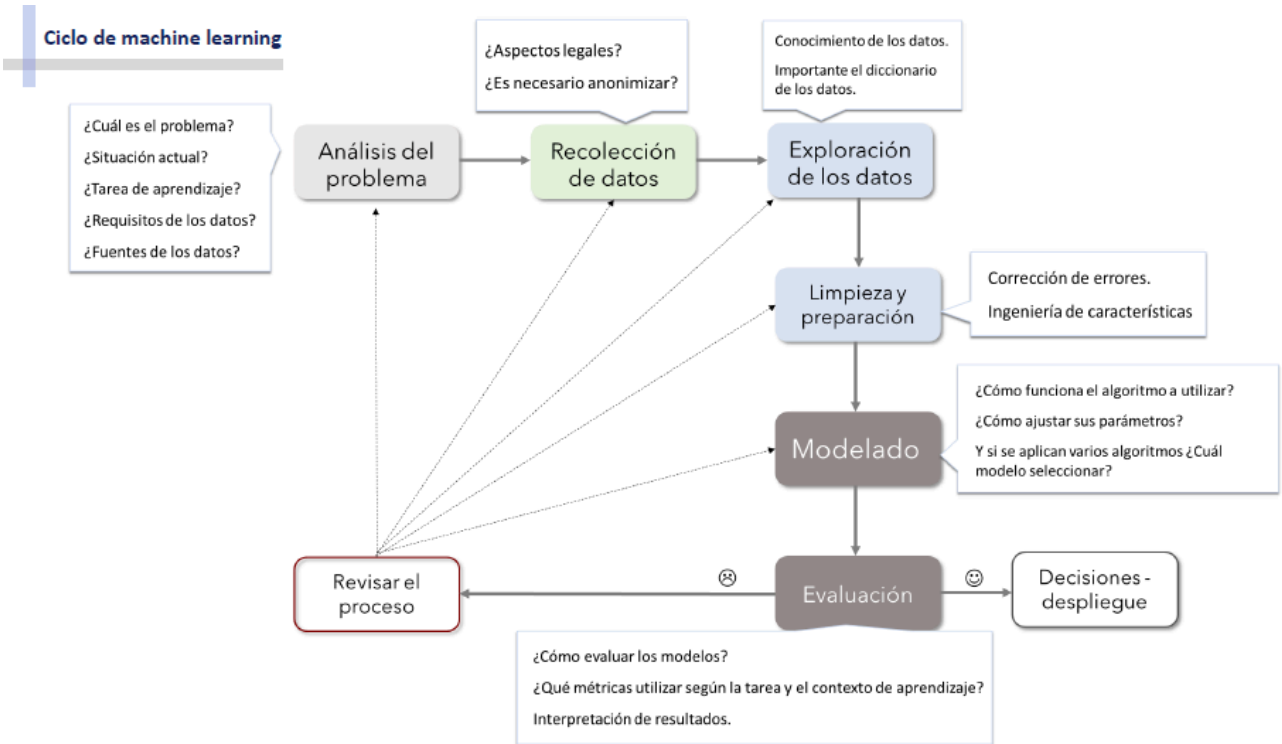

Objetivo general

Seguir el ciclo de ML del diagrama para resolver tu problema con dos rutas posibles: Regresión o Clasificación. Documenta cada paso en el notebook.

Objetivos de la sesión

Clase 1: Ruta A — Problema de Regresión 🛠️

- En esta ruta seguiremos el ciclo completo de machine learning: análisis del problema, recolección de datos, exploración, y limpieza y preparación, para luego pasar al modelado y evaluación. El foco estará en predecir un valor continuo usando un baseline de regresión lineal y una red neuronal para regresión. Ten en cuenta que el orden y la profundidad de cada paso pueden variar según el dataset de cada grupo (por ejemplo, si ya viene limpio o si requiere más ingeniería de variables). Documentaremos claramente cada decisión tomada, las métricas usadas (MAE/RMSE) y las conclusiones.

Clase 2: Ruta B — Problema de Clasificación🌳

- Aquí aplicaremos el mismo ciclo: análisis del problema, recolección de datos, exploración, y limpieza y preparación, seguido de modelado y evaluación. Clasificaremos casos binarios comparando regresión logística, perceptrón y un árbol aleatorio (Random Forest). El flujo podrá ajustarse según las características de los datos de cada equipo (por ejemplo, manejo de desbalance o codificación de categorías). Dejaremos registradas las decisiones de preprocesamiento, la elección de la métrica (p. ej., F1/ROC-AUC) y la definición del umbral cuando corresponda.

Semana 11 - Clase 1

🧭 Análisis del problema — Bike Sharing (UCI)

- **Problema de negocio (qué decisión habilita):** Predecir la **demanda diaria/horaria de bicicletas** para **planear capacidad** (flota, redistribución, turnos y mantenimiento), evitando **quedarse corto** (pérdida de ventas/servicio) o **sobredimensionar** (costos operativos altos).
- **Situación actual (contexto):** La empresa dispone de históricos de alquileres y clima, pero decide de forma **reactiva**. Se requiere una **estimación confiable** de la demanda para calendarizar personal y mover inventario (bicicletas) con anticipación.
- **Tarea de aprendizaje: Regresión supervisada.** Variable objetivo continua: `cnt` = número de alquileres (por **hora** o por **día**, según el archivo elegido).

Requisitos de datos (mínimos):

- Variables **exógenas (no estan influidas por ruido u otras variables)** disponibles antes de la decisión: clima (`temp`, `humidity`, `windspeed`, `weather`) y calendario (`season`, `holiday`, `workingday`, `hour/weekday`).
- **Calidad aceptable:** $<$5–10% de datos nulos manejables, tipificación correcta y **sin fuga de información**.

Fuentes de datos:

- **UCI Bike Sharing Dataset** (público): archivos `day.csv` / `hour.csv`.

  En este caso se puede acceder al recurso original, el cual es:

  https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset
- **Diccionario de variables** provisto en el repositorio original.

Variables Table

Variable Name	Role	Type	Description	Units	Missing Values
instant	ID	Integer	record index		no
dteday	Feature	Date	date		no
season	Feature	Categorical	1:winter, 2:spring, 3:summer, 4:fall		no
yr	Feature	Categorical	year (0: 2011, 1: 2012)		no
mnth	Feature	Categorical	month (1 to 12)		no
hr	Feature	Categorical	hour (0 to 23)		no
holiday	Feature	Binary	weather day is holiday or not (extracted from http://dchr.dc.gov/page/holiday-schedule)		no

Criterio de éxito (métrica + umbral de negocio):

- Métrica principal: **RMSE** (o **MAE** si hay outliers relevantes).
- Objetivo operativo (ejemplo): **RMSE ≤ 15 alquileres/hora** o **MAE ≤ 10**, consistente en test.

Riesgos y supuestos:

- **Estacionalidad/feriados** impactan fuertemente la demanda.
- **Cambios de política** o eventos atípicos pueden romper patrones.
- No se usan datos personales; dataset **agregado y no sensible**.

📥 Recolección de datos — Bike Sharing (UCI)

Usaremos el dataset público **UCI Bike Sharing**. Página del repositorio: https://archive.ics.uci.edu/ml/datasets/Bike+Sharing+Dataset. Descarga directa (ZIP): https://archive.ics.uci.edu/ml/machine-learning-databases/00275/Bike-Sharing-Dataset.zip. Trabajaremos con **una sola granularidad** (día `day.csv` u hora `hour.csv`) y registraremos en el notebook el **enlace de origen** y la **fecha de descarga** para trazabilidad. Antes de modelar, haremos una verificación básica: tipos correctos, rangos razonables y nulos manejables; variables clave: objetivo `cnt`, clima (`temp`, `humidity`, `windspeed`, `weather`) y calendario (`season`, `holiday`, `workingday`, `weekday`, `hour` si aplica).

Aspectos legales y privacidad. Este dataset es agregado y no contiene identificadores personales, por lo que **no requiere anonimización adicional** en uso académico. Si algún equipo lo combina con datos propios, debe documentar la finalidad, eliminar identificadores directos, agrupar o truncar campos sensibles y retener solo lo necesario, conforme a la **Ley 1581 de 2012 (Habeas Data)** en Colombia.

```
# ============================================================
# CARGA CORRECTA DEL DATASET "BIKE SHARING (UCI)" EN COLAB
# ------------------------------------------------------------
# Objetivo de esta celda:
# 1) Descargar el ZIP oficial desde UCI.
# 2) Descomprimirlo en el entorno de Colab.
# 3) Elegir la granularidad (día u hora) y cargar el CSV a pandas.
# 4) Convertir fechas a tipo datetime y revisar tipos de datos.
# 5) Mostrar un diccionario claro de variables (qué significa cada una).
# 6) Hacer verificaciones básicas: tamaño, nulos, muestra de filas.
# ------------------------------------------------------------
# Nota: Esta celda está MUY comentada a propósito, para personas
#       que están empezando con Python y Colab.
# ============================================================

import os
import io
import zipfile
import urllib.request
import pandas as pd

# ------------------------------------------------------------
# 1) CONFIGURACIÓN BÁSICA DEL PROYECTO (FÁCIL DE EDITAR)
# ------------------------------------------------------------

# Enlace oficial del ZIP en el repositorio UCI:
#UCI_ZIP_URL = "https://archive.ics.uci.edu/ml/machine-learning-databases/00275/Bike-Sharing-Dataset.zip"

# El usuario puede elegir la granularidad aquí:
#   - "day"  -> carga el archivo day.csv  (agregado por día)
#   - "hour" -> carga el archivo hour.csv (agregado por hora)
GRANULARITY = "hour"  # <-- Cambia a "day" si quieres trabajar por día

# Carpeta donde guardaremos los archivos descomprimidos
DATA_DIR = "/content/bike_sharing_data"

# ------------------------------------------------------------
# 2) DESCARGA DEL ZIP DESDE UCI
#    No requiere instalar nada extra. Usamos la librería estándar.
# ------------------------------------------------------------
```

```
#os.makedirs(DATA_DIR, exist_ok=True)
zip_path = os.path.join(DATA_DIR, "Bike-Sharing-Dataset.zip")

#print("Descargando ZIP desde UCI (puede tardar unos segundos)...")
#urllib.request.urlretrieve(UCI_ZIP_URL, zip_path)
#print("Descarga completa:", zip_path)

# ------------------------------------------------------------
# 3) DESCOMPRESIÓN DEL ZIP
# ------------------------------------------------------------
print("Descomprimiendo archivos...")
with zipfile.ZipFile(zip_path, 'r') as z:
    z.extractall(DATA_DIR)

print("Contenido descomprimido en:", DATA_DIR)
print("Archivos disponibles:", os.listdir(DATA_DIR))

# ------------------------------------------------------------
# 4) ELECCIÓN DEL CSV SEGÚN LA GRANULARIDAD
# ------------------------------------------------------------
if GRANULARITY == "day":
    csv_path = os.path.join(DATA_DIR, "day.csv")
elif GRANULARITY == "hour":
    csv_path = os.path.join(DATA_DIR, "hour.csv")
else:
    raise ValueError("GRANULARITY debe ser 'day' u 'hour'.")

if not os.path.exists(csv_path):
    raise FileNotFoundError(f"No se encontró el archivo esperado: {csv_path}")

print(f"Granularidad elegida: {GRANULARITY.upper()} -> Cargando {os.path.basename(csv_path)}")

# ------------------------------------------------------------
# 5) CARGA DEL CSV CON PANDAS
#    - parse_dates convierte la columna de fecha a tipo datetime (si existe).
#    - keep_default_na=True: pandas interpretará valores vacíos como NA.
# ------------------------------------------------------------
# En ambos CSV existe la columna 'dteday' (fecha). La parseamos si está presente.
parse_cols = ["dteday"]  # Si la columna no existe, pandas la ignorará.
df = pd.read_csv(csv_path, parse_dates=parse_cols, dayfirst=False, keep_default_na=True)

# ------------------------------------------------------------
# 6) DICCIONARIO DE VARIABLES
#    Explicamos, en español y de forma clara, qué significa cada columna.
#    (Puede que en tu CSV haya leves diferencias; este diccionario cubre lo estándar.)
# ------------------------------------------------------------
variable_dict = {
    # Identificadores / fecha
    "instant": "Índice de la fila (identificador incremental).",
    "dteday": "Fecha del registro (tipo datetime).",
    "season": "Estación del año (1: invierno, 2: primavera, 3: verano, 4: otoño) *codificación UCI.",
    "yr": "Año (0: primer año del dataset, 1: segundo año).",
    "mnth": "Mes del año (1 a 12).",
    "hr": "Hora del día (0 a 23) — solo en hour.csv.",
    "holiday": "Indica si el día es festivo (1) o no (0).",
    "weekday": "Día de la semana (0: domingo… 6: sábado).",
    "workingday": "Día laboral (1) o no (0) — excluye fines de semana y festivos.",
    # Clima
    "weathersit": "Situación del clima (1: bueno, 2: nubes/neblina, 3: lluvia ligera, 4: lluvia fuerte/nieve).",
    "temp": "Temperatura normalizada (0 a 1) — basada en temperatura en °C.",
    "atemp": "Temperatura aparente normalizada (sensación térmica).",
    "hum": "Humedad normalizada (0 a 1).",
    "windspeed": "Velocidad del viento normalizada (0 a 1).",
    # Objetivo y componentes
    "casual": "Número de alquileres por usuarios casuales (no registrados).",
    "registered": "Número de alquileres por usuarios registrados.",
    "cnt": "Número total de alquileres (objetivo para regresión)."
}

# Mostramos el diccionario como una tabla legible
dict_df = pd.DataFrame(
    [(k, variable_dict.get(k, "(desconocida en este diccionario)")) for k in df.columns],
    columns=["columna", "significado"]
```

```
)

print("\n=== DICCIONARIO DE VARIABLES (según columnas presentes) ===")
print(dict_df.to_string(index=False))

# ------------------------------------------------------------
# 7) ARREGLOS Y TIPOS DE DATOS
#    - Confirmamos que 'dteday' está en datetime.
#    - Revisamos tipos básicos y rangos.
# ------------------------------------------------------------
if "dteday" in df.columns:
    # Ya la parseamos como datetime en read_csv; confirmamos:
    print("\nTipo de 'dteday':", df["dteday"].dtype)

print("\n=== TIPOS DE DATOS (pandas dtypes) ===")
print(df.dtypes)

# ------------------------------------------------------------
# 8) VERIFICACIONES BÁSICAS DE CALIDAD
# ------------------------------------------------------------
print("\n=== DIMENSIONES DEL DATASET ===")
print("Filas:", len(df), "| Columnas:", df.shape[1])

print("\n=== NULOS POR COLUMNA (valores faltantes) ===")
print(df.isna().sum())



# ------------------------------------------------------------
# 9) SUGERENCIA PEDAGÓGICA
#    Si estamos en 'hour.csv', a menudo es útil crear una columna 'hour' si no existe,
#    o asegurar que 'hr' está en entero. También es buena práctica comprobar valores únicos.
# ------------------------------------------------------------
if GRANULARITY == "hour":
    # Aseguramos que hr sea entero (debería serlo ya).
    if "hr" in df.columns:
        df["hr"] = df["hr"].astype(int)
        print("\nValores únicos de 'hr' (deberían ser 0..23):", sorted(df["hr"].unique())[:10], "...")

# ------------------------------------------------------------
# 10) (OPCIONAL) GUARDAR UNA COPIA LIMPIA INICIAL
#     Esto ayuda a mantener una "versión base" antes de empezar la preparación.
# ------------------------------------------------------------
base_csv_path = os.path.join(DATA_DIR, f"base_{GRANULARITY}.csv")
df.to_csv(base_csv_path, index=False)
print(f"\nCopia base guardada en: {base_csv_path}")

# Listo: en las siguientes celdas se recomienda continuar con:
# - EXPLORACIÓN (estadísticos, gráficos básicos)
# - LIMPIEZA/PREPARACIÓN (nulos, tipos, escalado, codificación)
# - PARTICIÓN (train/test)
# - MODELADO (Regresión Lineal vs Perceptrón/Adaline/MLP)
# - EVALUACIÓN (MAE/RMSE y residuales)
# - EVALUACIÓN (MAE/RMSE y residuales)
```

```
Descomprimiendo archivos...
Contenido descomprimido en: /content/bike_sharing_data
Archivos disponibles: ['Readme.txt', 'hour.csv', 'Bike-Sharing-Dataset.zip', 'day.csv']
Granularidad elegida: HOUR -> Cargando hour.csv

=== DICCIONARIO DE VARIABLES (según columnas presentes) ===
   columna                                                                                  significado
   instant                                                   Índice de la fila (identificador incremental).
    dteday                                                               Fecha del registro (tipo datetime).
    season        Estación del año (1: invierno, 2: primavera, 3: verano, 4: otoño) *codificación UCI.
        yr                                                Año (0: primer año del dataset, 1: segundo año).
      mnth                                                                        Mes del año (1 a 12).
        hr                                                       Hora del día (0 a 23) — solo en hour.csv.
   holiday                                                       Indica si el día es festivo (1) o no (0).
   weekday                                                       Día de la semana (0: domingo… 6: sábado).
workingday                                  Día laboral (1) o no (0) — excluye fines de semana y festivos.
weathersit Situación del clima (1: bueno, 2: nubes/neblina, 3: lluvia ligera, 4: lluvia fuerte/nieve).
      temp                                  Temperatura normalizada (0 a 1) — basada en temperatura en °C.
     atemp                                            Temperatura aparente normalizada (sensación térmica).
```

```
       hum                                                                Humedad normalizada (0 a 1).
 windspeed                                                   Velocidad del viento normalizada (0 a 1).
    casual                                   Número de alquileres por usuarios casuales (no registrados).
registered                                                  Número de alquileres por usuarios registrados.
       cnt                                          Número total de alquileres (objetivo para regresión).

Tipo de 'dteday': datetime64[ns]

=== TIPOS DE DATOS (pandas dtypes) ===
instant                int64
dteday        datetime64[ns]
season                 int64
yr                     int64
mnth                   int64
hr                     int64
holiday                int64
weekday                int64
workingday             int64
weathersit             int64
temp                 float64
atemp                float64
hum                  float64
windspeed            float64
casual                 int64
registered             int64
cnt                    int64
dtype: object

=== DIMENSIONES DEL DATASET ===
Filas: 17379 | Columnas: 17

=== NULOS POR COLUMNA (valores faltantes) ===
instant       0
dteday        0
season        0
yr            0
mnth          0
hr            0
```

```
# Vista del data frame
print("\n=== VISTA RÁPIDA (head) ===")
df.head()
```

```
=== VISTA RÁPIDA (head) ===
```

	instant	dteday	season	yr	mnth	hr	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual
0	1	2011-01-01	1	0	1	0	0	6	0	1	0.24	0.2879	0.81	0.0	3
1	2	2011-01-01	1	0	1	1	0	6	0	1	0.22	0.2727	0.80	0.0	8
2	3	2011-01-01	1	0	1	2	0	6	0	1	0.22	0.2727	0.80	0.0	5
3	4	2011-01-01	1	0	1	3	0	6	0	1	0.24	0.2879	0.75	0.0	3
4	5	2011-01-01	1	0	1	4	0	6	0	1	0.24	0.2879	0.75	0.0	0

🔍 Exploración y conocimiento de los datos — Bike Sharing (UCI)

En esta fase buscamos **entender la forma y el contexto** del dataset antes de modelar. Revisamos tamaño (filas/columnas), tipos de variables, rangos y valores atípicos, y verificamos si la granularidad elegida (**día** u **hora**) cubre estacionalidad y feriados. La idea es detectar patrones generales (tendencias por clima y calendario), posibles **nulos** o codificaciones inusuales, y confirmar que la variable objetivo `cnt` refleja correctamente la demanda.

Descripción breve. Empezamos con una síntesis: periodo cubierto, frecuencia (día/hora), medias y dispersiones de las variables numéricas, y distribución básica de `cnt`. Si existen transformaciones previas (p. ej., temperaturas normalizadas 0–1), se anotan para no duplicarlas. Si hay desbalance temporal (pocos registros en ciertos meses/horas), se documenta porque afectará la validación.

📚 Diccionario de datos (significado de variables)

Variable	Significado breve
`instant`	Índice incremental del registro.
`dteday`	Fecha del registro (día).
`season`	Estación (1 invierno, 2 primavera, 3 verano, 4 otoño).
`yr`	Año (0 o 1 según el año en el dataset).
`mnth`	Mes (1–12).
`hr`	Hora del día (0–23, solo en `hour.csv`).
`holiday`	Indicador de festivo (1 sí, 0 no).
`weekday`	Día de la semana (0 domingo … 6 sábado).
`workingday`	Día laboral (1 sí, 0 no; excluye fines de semana y festivos).
`weathersit`	Clima (1 bueno, 2 nublado/neblina, 3 lluvia ligera, 4 lluvia fuerte/nieve).
`temp`	Temperatura normalizada (0–1).
`atemp`	Sensación térmica normalizada (0–1).
`hum`	Humedad relativa normalizada (0–1).
`windspeed`	Velocidad del viento normalizada (0–1).
`casual`	Alquileres de usuarios casuales (no registrados).
`registered`	Alquileres de usuarios registrados.
`cnt`	**Objetivo**: total de alquileres (`casual + registered`).

> Nota: algunas columnas son **categóricas codificadas como números** (p. ej., `season`, `weathersit`, `weekday`). Se interpretan como categorías, no como cantidades continuas.

🖼️ Guía rápida para gráficos descriptivos

Histogramas sirven para ver la **distribución** de una variable numérica (p. ej., `cnt`, `temp`, `hum`) y detectar asimetrías o multimodalidad. Úsalos cuando quieras responder "¿cómo se reparte esta variable?" o comparar distribuciones por subgrupos (ej., histograma de `cnt` por `season`).

Box plots son útiles para comparar **niveles y dispersión** entre **categorías** y detectar **outliers** (p. ej., `cnt` por `weekday`, `weathersit` o `hour`). Son ideales para responder "¿qué categoría tiende a tener valores más altos/estables?" y visualizar mediana y cuartiles.

Series/line plots (si trabajas por hora o día) muestran **tendencias y estacionalidad** en el tiempo (picos por hora punta, patrones de fin de semana). Ayudan a ver ciclos diarios/semanales y posibles quiebres.

Relaciones bivariadas: un **scatter** `temp` vs `cnt` sugiere relación con clima; un **scatter** `hr` vs `cnt` revela picos horarios. Si aparece curvatura o bandas, puede ser señal de **no linealidad** o de variables omitidas.

Qué dejamos documentado.

Un párrafo con los **hallazgos descriptivos clave**: patrón de demanda por hora/día, efecto visible del clima y presencia de outliers o nulos. Además, reportamos **correlaciones** entre `cnt` y las variables numéricas con los coeficientes **de Pearson** (relación **lineal**) y **de Spearman** (relación **monótona**, robusta a no linealidades y outliers). Si Pearson es alto y Spearman similar, sugiere relación aproximadamente lineal; si Spearman es alto pero Pearson bajo, puede haber relación no lineal (o influencia de rangos). Esta evidencia guía la **preparación** (p. ej., transformaciones/escala) y anticipa si una **regresión lineal** podría bastar o si un **modelo no lineal** agregará valor.

```
!pip -q install ydata-profiling -q
```

```
━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 400.4/400.4 kB 9.1 MB/s eta 0:00:00
━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 296.7/296.7 kB 21.6 MB/s eta 0:00:00
━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 3.1/3.1 MB 58.8 MB/s eta 0:00:00
━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 679.7/679.7 kB 38.1 MB/s eta 0:00:00
```

```
━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 105.4/105.4 kB 7.8 MB/s eta 0:00:00
━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 72.0/72.0 kB 5.7 MB/s eta 0:00:00
```

```
# Utilizamos la libreria recien instalada
from ydata_profiling import ProfileReport

profile = ProfileReport(df)
profile.to_notebook_iframe()  # lo embebe como iframe (funciona bien en Colab)
# Descarga el profile como archivo html
profile.to_file("reporte_perfil.html")
print("Archivo guardado:", "/content/reporte_perfil.html")
```

```
Summarize dataset: 100%                                    147/147 [00:30<00:00,  5.10it/s, Completed]

  0%|          | 0/17 [00:00<?, ?it/s]
 18%|▉▉         | 3/17 [00:00<00:01, 12.69it/s]
 41%|▉▉▉▉       | 7/17 [00:00<00:00, 14.26it/s]
 53%|▉▉▉▉▉      | 9/17 [00:00<00:00, 15.06it/s]
 71%|▉▉▉▉▉▉▉    | 12/17 [00:00<00:00, 16.39it/s]
100%|▉▉▉▉▉▉▉▉▉▉| 17/17 [00:00<00:00, 17.43it/s]
Generate report structure: 100%                            1/1 [00:06<00:00,  6.27s/it]

Render HTML: 100%                                          1/1 [00:01<00:00,  1.93s/it]
```

YData Profiling Report

Overview

Overview | Alerts 19 | Reproduction

Dataset statistics

Number of variables	17
Number of observations	17379
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	2.3 MiB
Average record size in memory	136.0 B

Variable types

Numeric	11
DateTime	1
Categorical	5

Variables

Select Columns

instant

```
Export report to file: 100%                                1/1 [00:00<00:00, 21.46it/s]
Archivo guardado: /content/reporte_perfil.html
```

```
# Camino mas largo, pero enriqucedor para conocer otro tipo de gráficos.
# ============================================================
# EXPLORACIÓN DESCRIPTIVA — UCI Bike Sharing (day/hour)
# ------------------------------------------------------------
# Qué hace esta celda (paso a paso):
# 1) Grafica histogramas (forma de la distribución).
# 2) Grafica boxplots por categorías (estación, clima, etc.).
# 3) Grafica tendencias (promedios por hora / weekday).
# 4) Grafica relaciones (scatter) cnt vs temp / hr.
# 5) Calcula correlación Pearson y Spearman y dibuja heatmaps.
# ------------------------------------------------------------
# Requisitos: SOLO matplotlib y pandas (ya vienen en Colab).
# ============================================================

# ========== 0) CONFIGURACIÓN DEL PROYECTO ==========
GRANULARITY = "hour"  # Cambia a "day" para trabajar por día
PRIMARY_TARGET = "cnt"  # Variable objetivo de demanda total

# ========== 1) DESCARGA Y CARGA ==========
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import plotly.express as px

# ========== 1) HISTOGRAMAS ==========
# Qué vemos: forma de la distribución (asimetría, colas, multimodalidad)
numeric_cols = [c for c in ["cnt","temp","atemp","hum","windspeed"] if c in df.columns]
for col in numeric_cols:
    plt.figure(figsize=(7,4))
    plt.hist(df[col].dropna(), bins=30)  # No definimos color explícito
    plt.title(f"Histograma de {col}")
    plt.xlabel(col)
    plt.ylabel("Frecuencia")
    plt.grid(True, alpha=0.3)
    plt.tight_layout()
    plt.show()

# ========== 2) BOXPLOTS POR CATEGORÍAS ==========
# Qué vemos: diferencias de nivel y dispersión entre categorías (y outliers)
def boxplot_by_category(df, cat_col, y_col=PRIMARY_TARGET):
    if cat_col not in df.columns or y_col not in df.columns:
        return
    data = [g[y_col].values for _, g in df.groupby(cat_col)]
    labels = [str(lbl) for lbl in sorted(df[cat_col].unique())]
    plt.figure(figsize=(8,4))
    plt.boxplot(data, labels=labels, showmeans=True)
    plt.title(f"{y_col} por {cat_col}")
    plt.xlabel(cat_col)
    plt.ylabel(y_col)
    plt.grid(True, axis='y', alpha=0.3)
    plt.tight_layout()
    plt.show()

for cat in ["season", "weathersit", "weekday"] + (["hr"] if GRANULARITY=="hour" and "hr" in df.columns else []):
    boxplot_by_category(df, cat, PRIMARY_TARGET)

# ========== 3) SERIES / TENDENCIAS ==========
# Qué vemos: patrones por hora y por día de la semana (picos, estacionalidad corta)
if GRANULARITY == "hour" and "hr" in df.columns:
    avg_by_hour = df.groupby("hr")[PRIMARY_TARGET].mean()
    plt.figure(figsize=(8,4))
    plt.plot(avg_by_hour.index, avg_by_hour.values, marker="o")  # sin color explícito
    plt.title("Promedio de alquileres por hora (cnt)")
    plt.xlabel("hr (0–23)")
    plt.ylabel("cnt (promedio)")
    plt.grid(True, alpha=0.3)
    plt.xticks(range(0,24,2))
    plt.tight_layout()
    plt.show()

avg_by_weekday = df.groupby("weekday")[PRIMARY_TARGET].mean()
plt.figure(figsize=(8,4))
plt.plot(avg_by_weekday.index, avg_by_weekday.values, marker="o")
```

```
plt.title("Promedio de alquileres por día de la semana (cnt)")
plt.xlabel("weekday (0=dom ... 6=sáb)")
plt.ylabel("cnt (promedio)")
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()

# ========== 4) SCATTER PLOTS (relaciones) ==========
# Qué vemos: relación bivariada y posibles no linealidades
def scatter_basic(x, y, x_label, y_label):
    plt.figure(figsize=(7,4))
    plt.scatter(x, y, s=10, alpha=0.4)  # sin color específico
    plt.title(f"{y_label} vs {x_label}")
    plt.xlabel(x_label)
    plt.ylabel(y_label)
    plt.grid(True, alpha=0.3)
    plt.tight_layout()
    plt.show()
# Detectar columnas numéricas y excluir el target
num_cols_all = df.select_dtypes(include=[np.number]).columns.tolist()
num_features = [c for c in num_cols_all if c != PRIMARY_TARGET]

# Generar un scatter por cada variable numérica vs cnt
for col in num_features:
    scatter_basic(df[col], df[PRIMARY_TARGET], f"{col}", f"{PRIMARY_TARGET} (alquileres)")

if "temp" in df.columns:
    scatter_basic(df["temp"], df[PRIMARY_TARGET], "temp (normalizada)", "cnt (alquileres)")

if GRANULARITY == "hour" and "hr" in df.columns:
    scatter_basic(df["hr"], df[PRIMARY_TARGET], "hr (hora del día)", "cnt (alquileres)")

# ========== 5) CORRELACIÓN PEARSON & SPEARMAN + HEATMAPS ==========
# Pearson: relación lineal. Spearman: relación monótona (por rangos; robusta a no linealidad/outliers)
num_df = df.select_dtypes(include=[np.number])

pearson_corr = num_df.corr(method="pearson")
spearman_corr = num_df.corr(method="spearman")

print("\n=== Correlación (Pearson) — top con cnt ===")
if PRIMARY_TARGET in pearson_corr.columns:
    print(pearson_corr[PRIMARY_TARGET].sort_values(ascending=False))

print("\n=== Correlación (Spearman) — top con cnt ===")
if PRIMARY_TARGET in spearman_corr.columns:
    print(spearman_corr[PRIMARY_TARGET].sort_values(ascending=False))

def heatmap_corr(corr_matrix, title, cmap="coolwarm"):
    # IMPORTANTE: se usa un colormap explícito porque el usuario lo pidió
    data = corr_matrix.values
    labels = corr_matrix.columns.tolist()
    n = data.shape[0]

    plt.figure(figsize=(max(6, n*0.5), max(5, n*0.5)))
    im = plt.imshow(data, cmap=cmap, vmin=-1, vmax=1)
    plt.title(title)
    cbar = plt.colorbar(im, fraction=0.046, pad=0.04)
    cbar.set_label("Coeficiente de correlación", rotation=90)

    plt.xticks(range(n), labels, rotation=90)
    plt.yticks(range(n), labels)

    # Anotar valores numéricos en cada celda
    for i in range(n):
        for j in range(n):
            plt.text(j, i, f"{data[i,j]:.2f}", ha="center", va="center", fontsize=8)

    plt.tight_layout()
    plt.show()

heatmap_corr(pearson_corr, "Matriz de correlación (Pearson) — variables numéricas", cmap="coolwarm")
heatmap_corr(spearman_corr, "Matriz de correlación (Spearman) — variables numéricas", cmap="coolwarm")
```

```
# ====== 6) Categóricas (PIE y SUNBURST) ======
# Pie simple por 'season' (proporción de registros)
if "season" in df.columns:
    tmp = df["season"].value_counts(normalize=True).reset_index()
    tmp.columns = ["season", "proporcion"]
    fig = px.pie(tmp, names="season", values="proporcion", title="Distribución de registros por season")
    fig.show()

# Sunburst ponderado por cnt: season -> weathersit (más útil que solo contar filas)
if all(c in df.columns for c in ["season","weathersit", PRIMARY_TARGET]):
    tmp2 = df.groupby(["season","weathersit"], as_index=False)[PRIMARY_TARGET].sum()
    fig2 = px.sunburst(tmp2, path=["season","weathersit"], values=PRIMARY_TARGET,
                       title=f"Sunburst de {PRIMARY_TARGET} por season y weathersit (suma)")
    fig2.show()


# ========== 7) MINI-GUÍA (interpretación) ==========
print("\nGuía de lectura:")
print("- Histogramas: forma de cada variable (asimetría, colas, multimodalidad).")
print("- Box plots: diferencias entre categorías (estación, clima, días) y outliers.")
print("- Series: picos horarios y patrón por weekday (si trabajas por hora).")
print("- Scatter: relaciones y posibles no linealidades (temp/hr vs cnt).")
print("- Correlación: Pearson (lineal) y Spearman (monótona).")
print("  Si Pearson y Spearman son similares y altos con cnt -> tendencia lineal;")
print("  si Spearman es alto y Pearson bajo -> relación no lineal o efecto de rangos/outliers.")
```

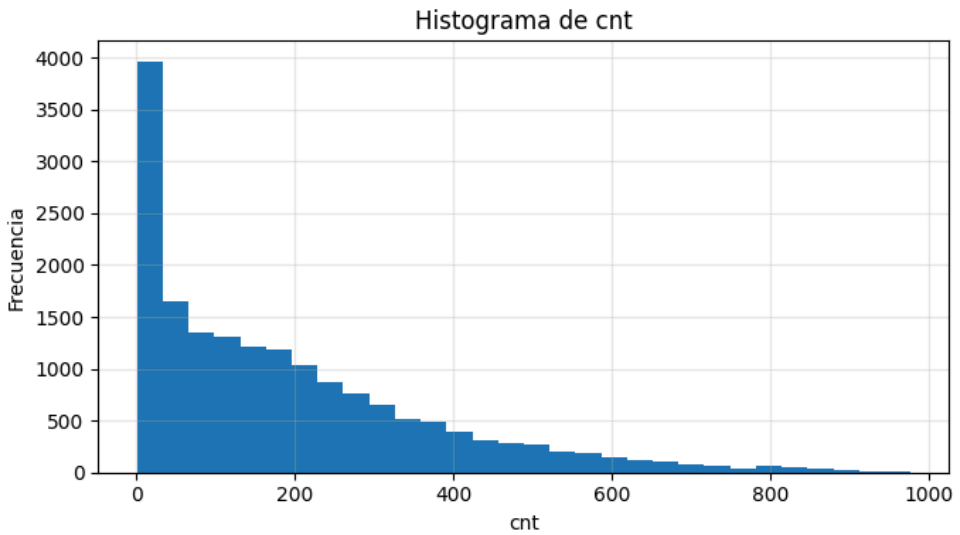
Histograma de cnt
Frecuencia
cnt
0
500
1000
1500
2000
2500
3000
3500
4000
0
200
400
600
800
1000

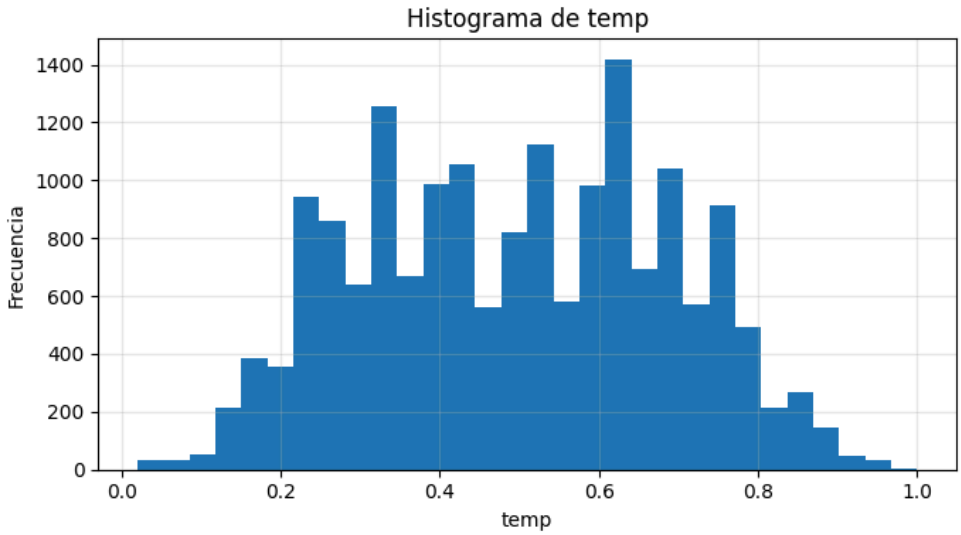
Histograma de temp
Frecuencia
temp
0
200
400
600
800
1000
1200
1400
0.0
0.2
0.4
0.6
0.8
1.0

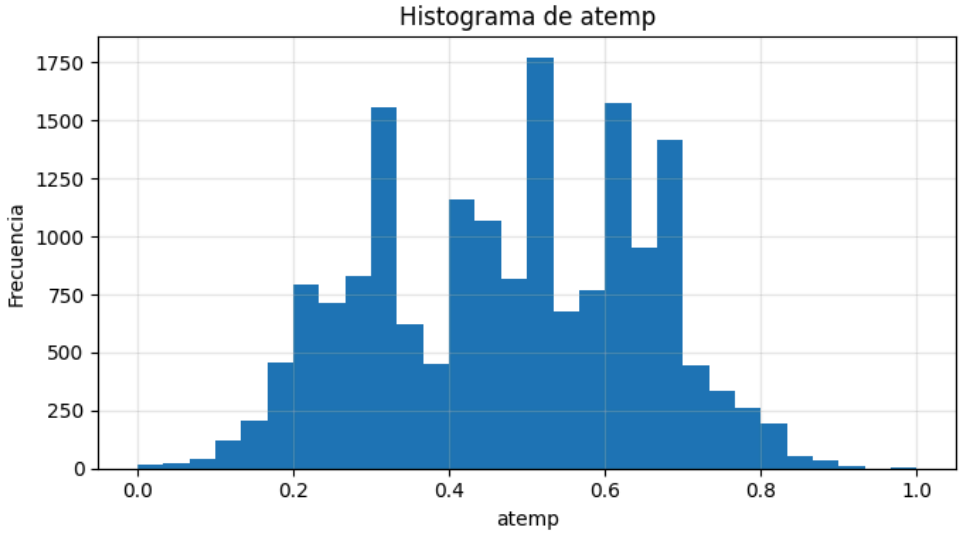
Histograma de atemp
Frecuencia
atemp
0
250
500
750
1000
1250
1500
1750
0.0
0.2
0.4
0.6
0.8
1.0

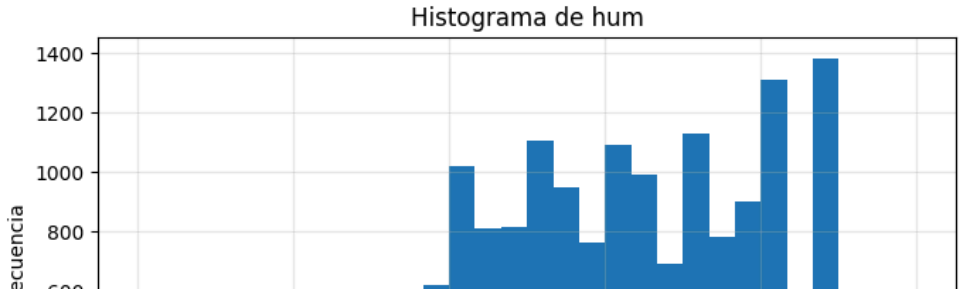
Histograma de hum
800
1000
1200
1400

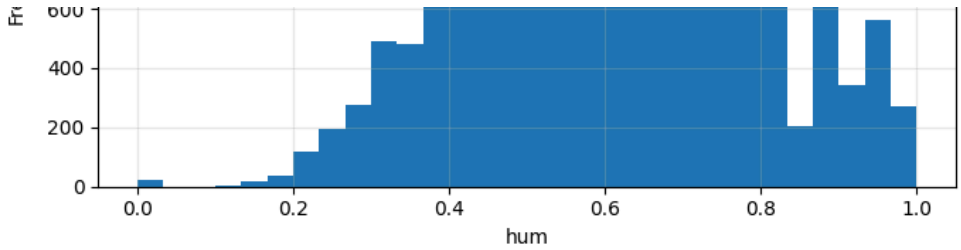

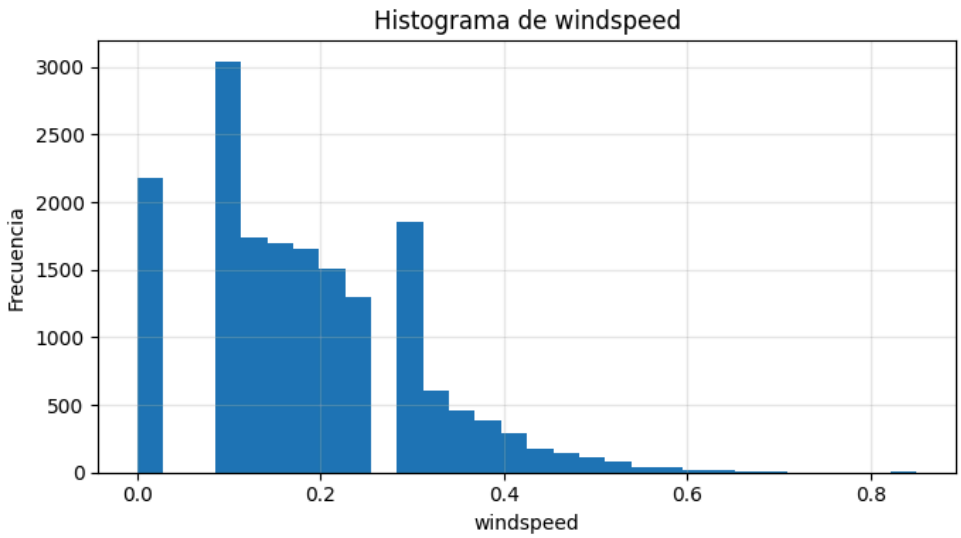


```
/tmp/ipykernel_9455/2666669698.py:46: MatplotlibDeprecationWarning: The 'labels' parameter of boxplot() has been renamed
  plt.boxplot(data, labels=labels, showmeans=True)
```

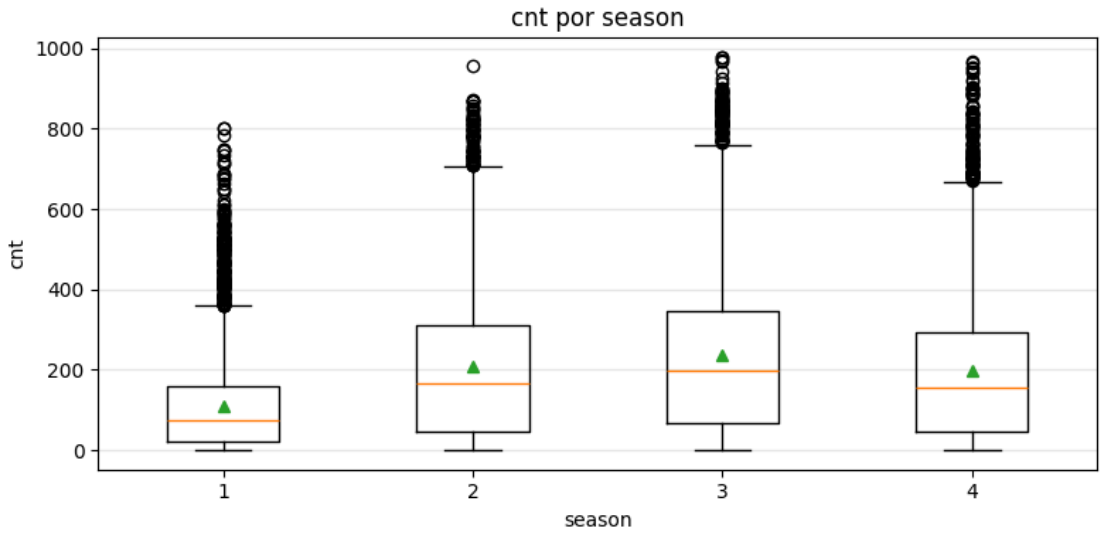


```
/tmp/ipykernel_9455/2666669698.py:46: MatplotlibDeprecationWarning: The 'labels' parameter of boxplot() has been renamed
  plt.boxplot(data, labels=labels, showmeans=True)
```

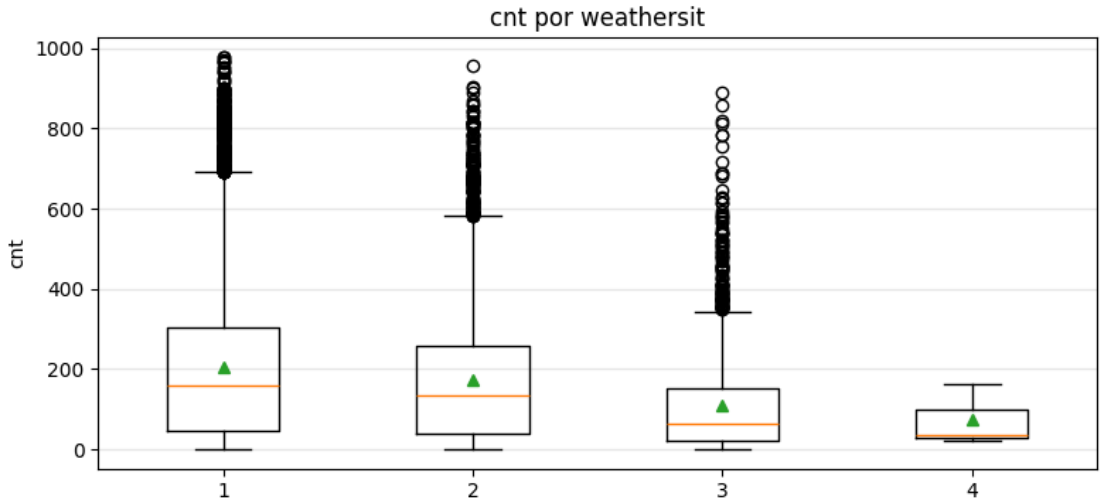

weathersit

```
/tmp/ipykernel_9455/2666669698.py:46: MatplotlibDeprecationWarning: The 'labels' parameter of boxplot() has been renamed
  plt.boxplot(data, labels=labels, showmeans=True)
```

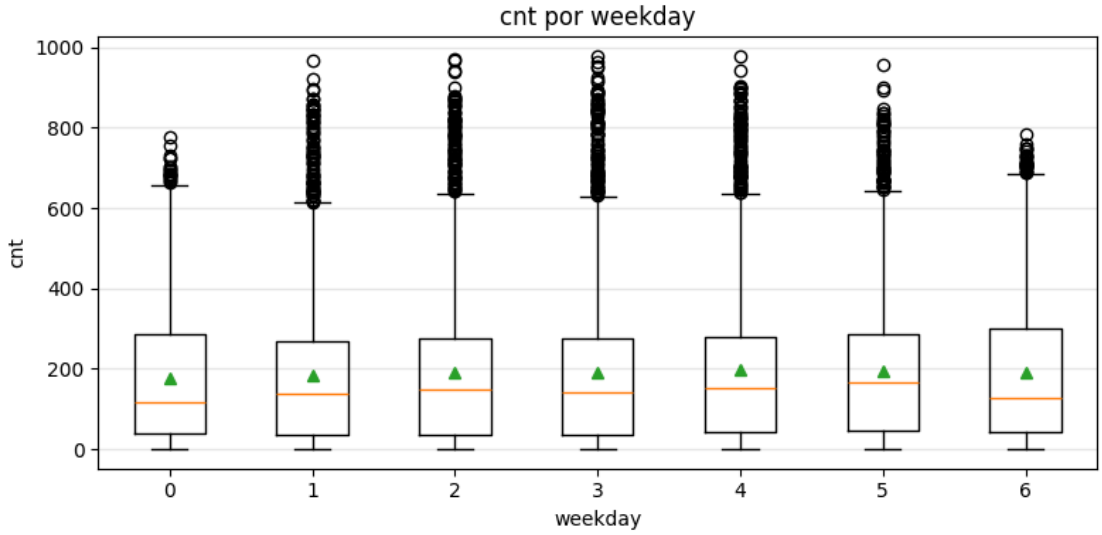


```
/tmp/ipykernel_9455/2666669698.py:46: MatplotlibDeprecationWarning: The 'labels' parameter of boxplot() has been renamed
  plt.boxplot(data, labels=labels, showmeans=True)
```

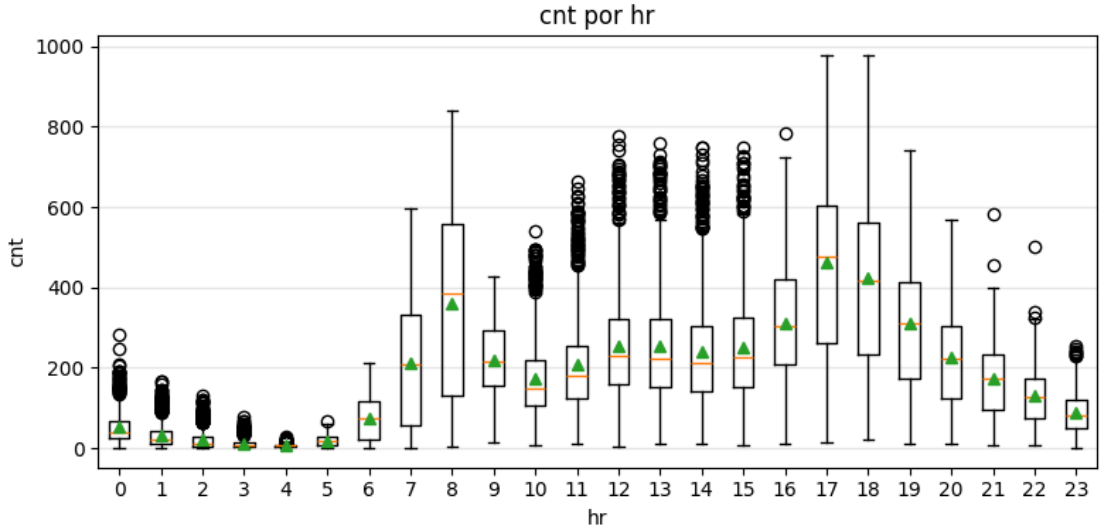

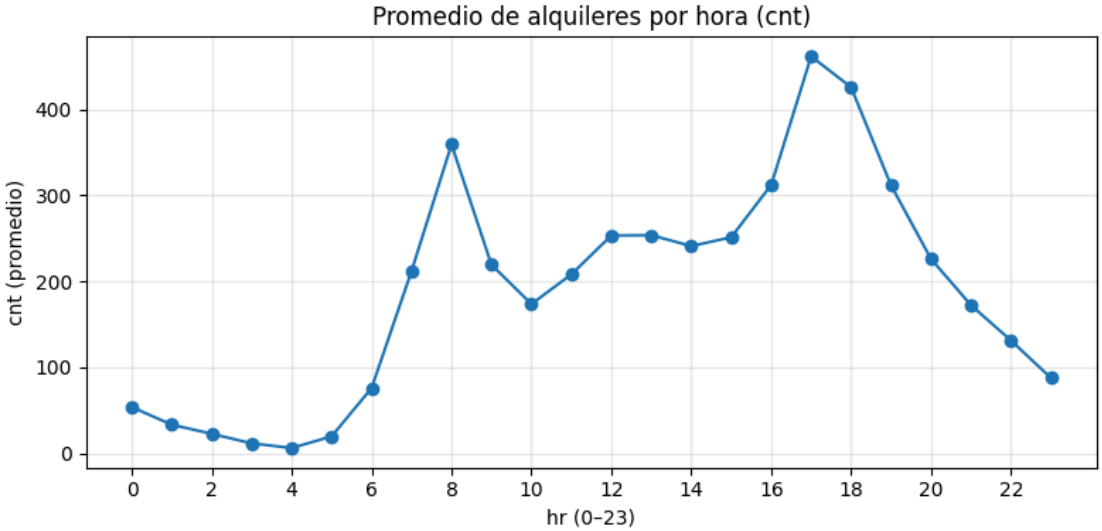

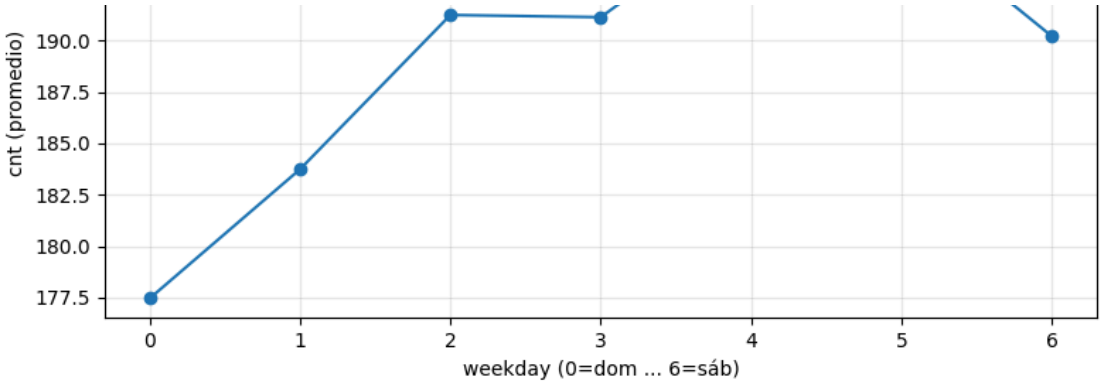
cnt (promedio)
190.0
187.5
185.0
182.5
180.0
177.5
0
1
2
3
4
5
6
weekday (0=dom ... 6=sáb)

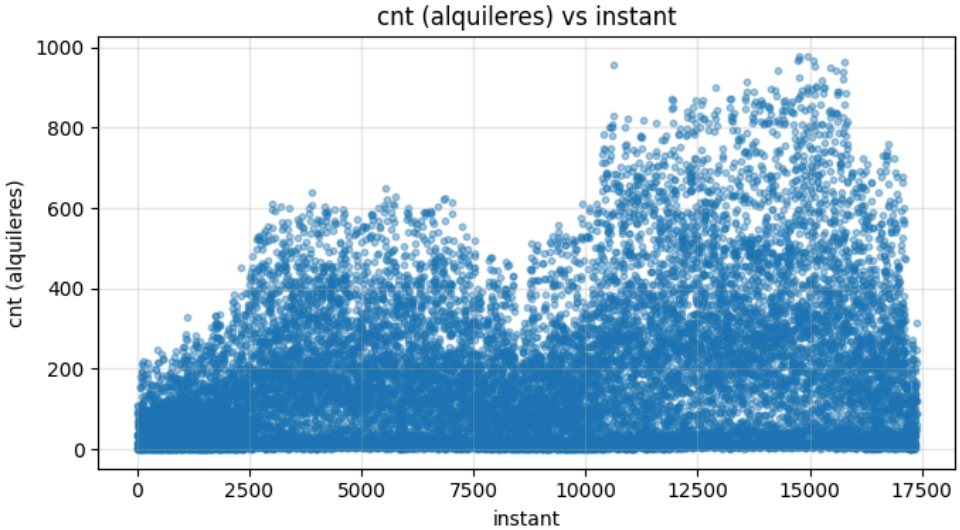
cnt (alquileres) vs instant
cnt (alquileres)
1000
800
600
400
200
0
0
2500
5000
7500
10000
12500
15000
17500
instant

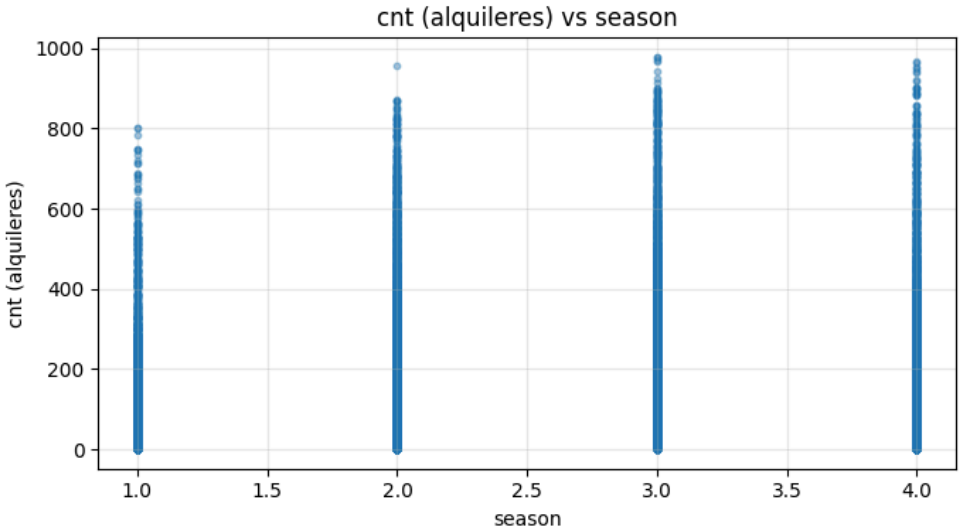
cnt (alquileres) vs season
cnt (alquileres)
1000
800
600
400
200
0
1.0
1.5
2.0
2.5
3.0
3.5
4.0
season

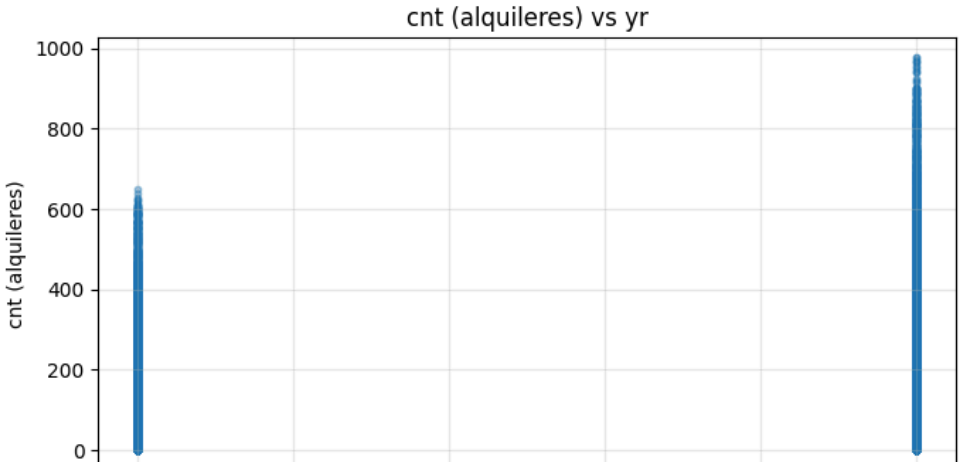
cnt (alquileres) vs yr
cnt (alquileres)
1000
800
600
400
200
0

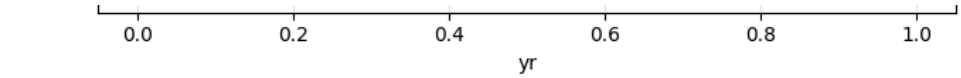
0.0
0.2
0.4
0.6
0.8
1.0
yr

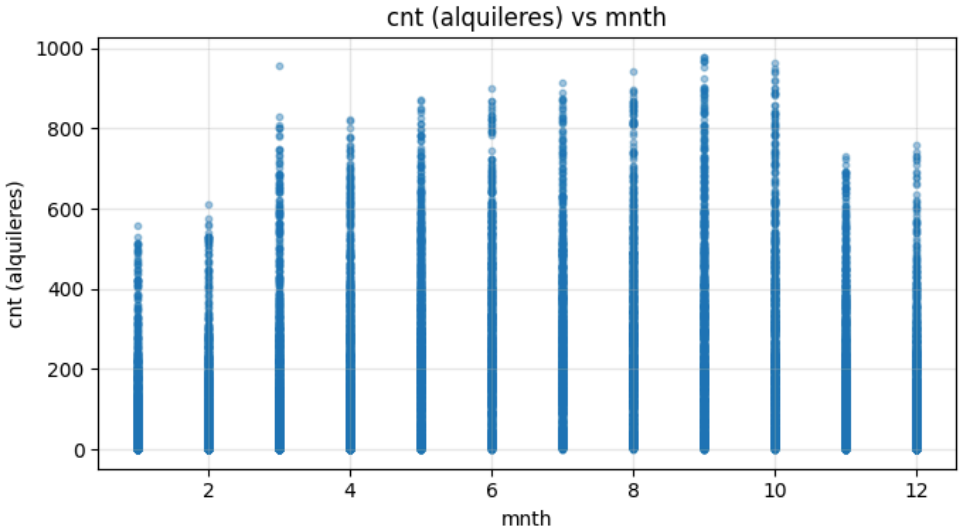
cnt (alquileres) vs mnth
cnt (alquileres)
mnth

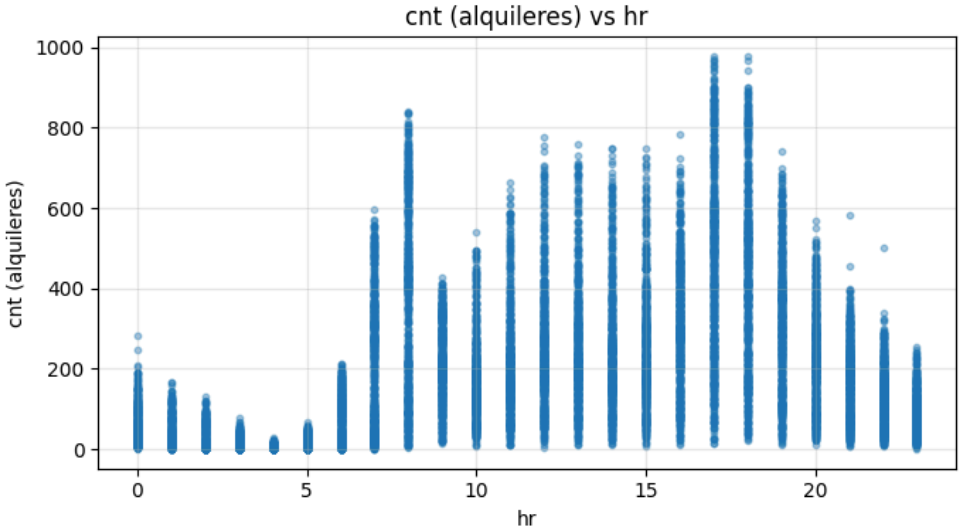
cnt (alquileres) vs hr
cnt (alquileres)
hr

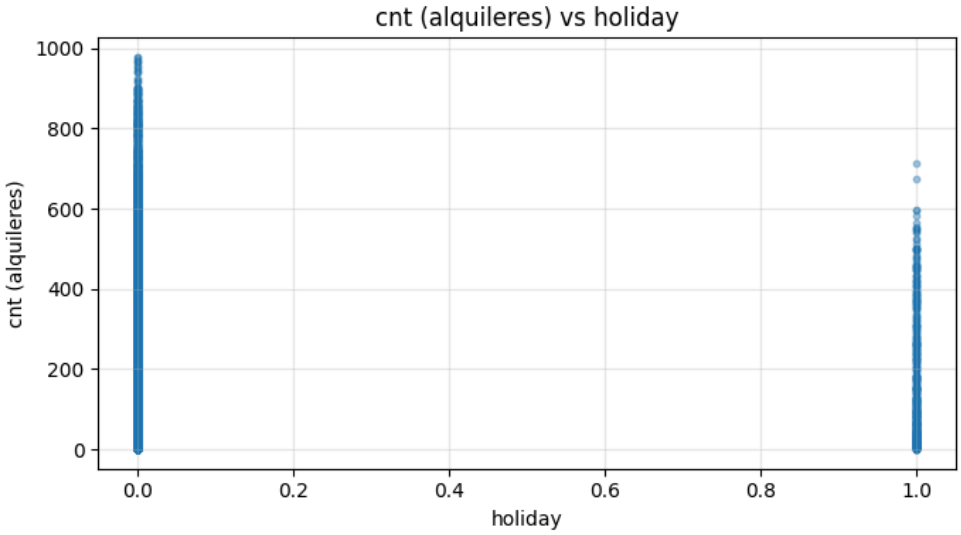
cnt (alquileres) vs holiday
cnt (alquileres)
holiday

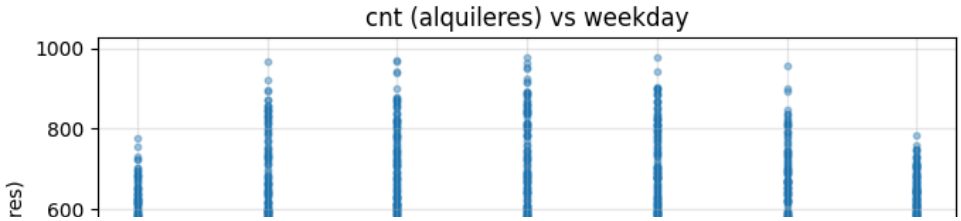
cnt (alquileres) vs weekday

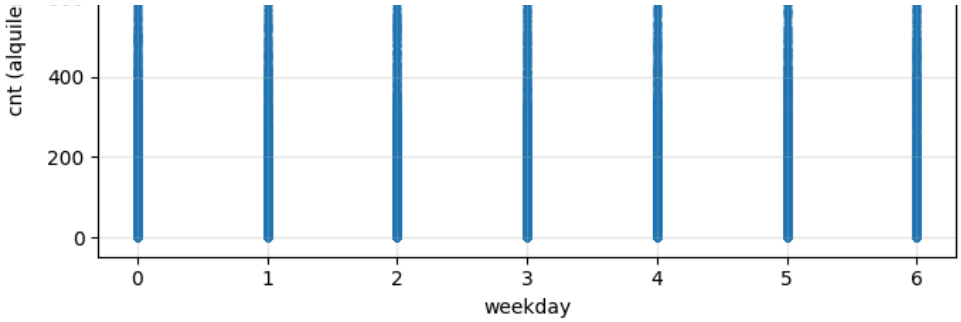
cnt (alquile
400
200
0
0
1
2
3
4
5
6
weekday

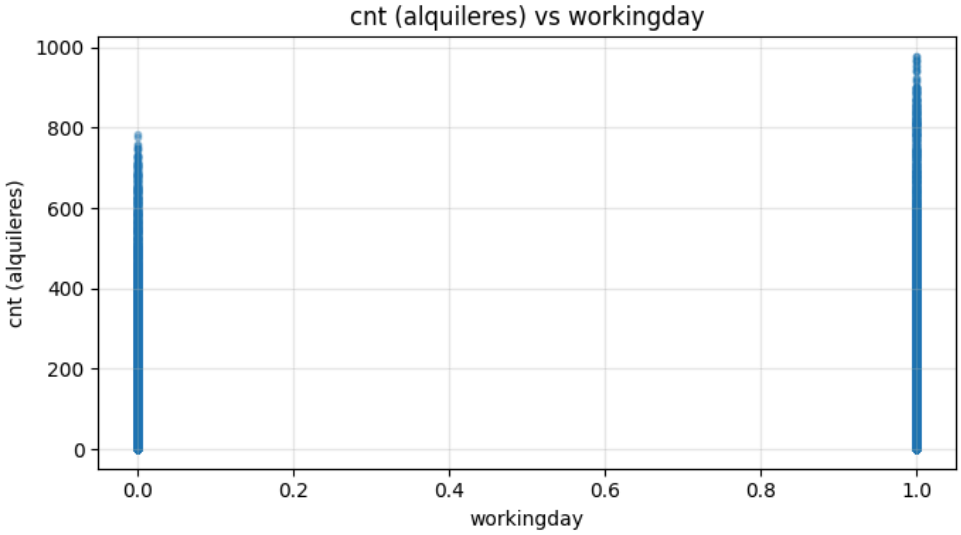
cnt (alquileres) vs workingday
1000
800
600
400
200
0
cnt (alquileres)
0.0
0.2
0.4
0.6
0.8
1.0
workingday

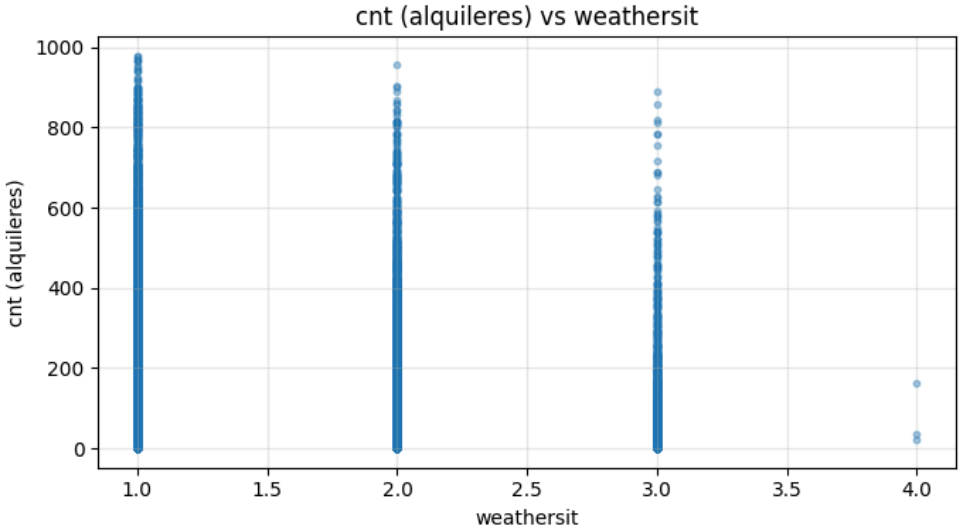
cnt (alquileres) vs weathersit
1000
800
600
400
200
0
cnt (alquileres)
1.0
1.5
2.0
2.5
3.0
3.5
4.0
weathersit

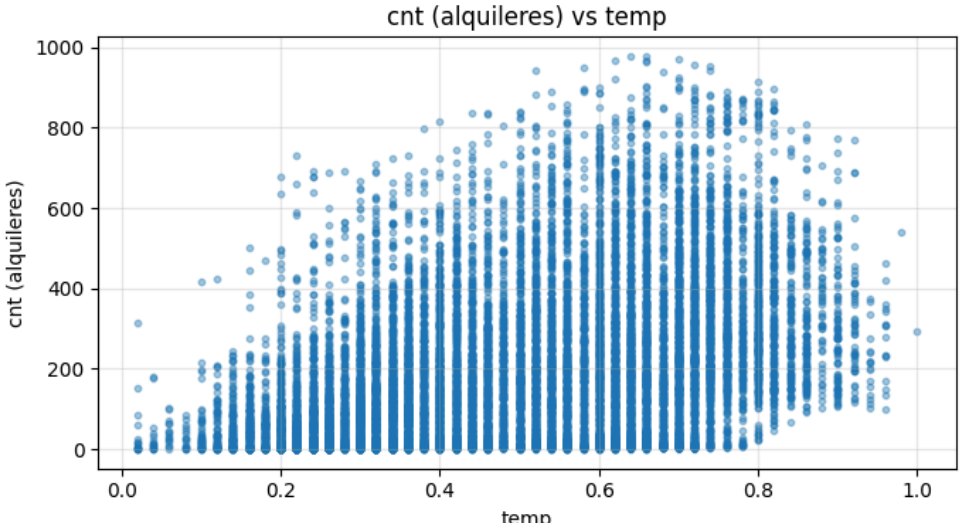
cnt (alquileres) vs temp
1000
800
600
400
200
0
cnt (alquileres)
0.0
0.2
0.4
0.6
0.8
1.0
temp

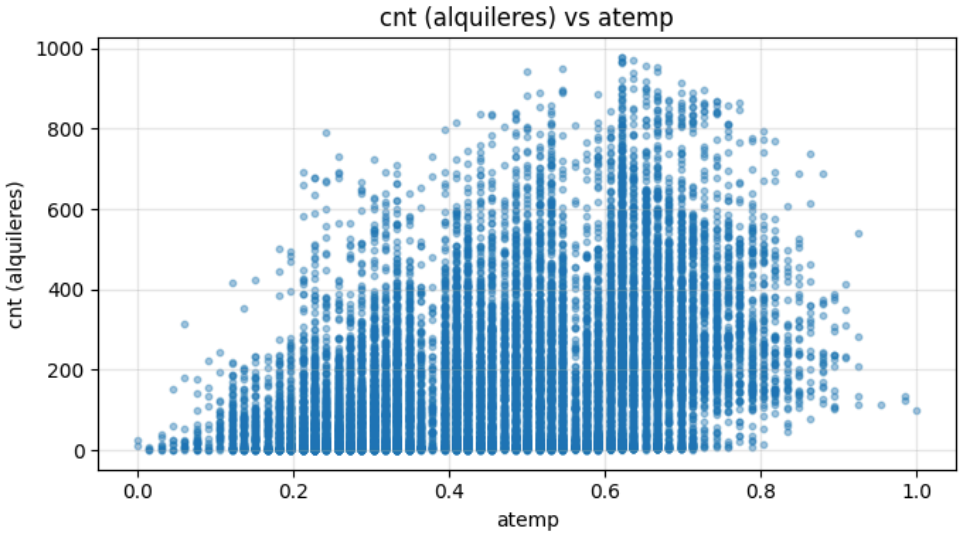
cnt (alquileres) vs atemp
cnt (alquileres)
atemp
0
200
400
600
800
1000
0.0
0.2
0.4
0.6
0.8
1.0

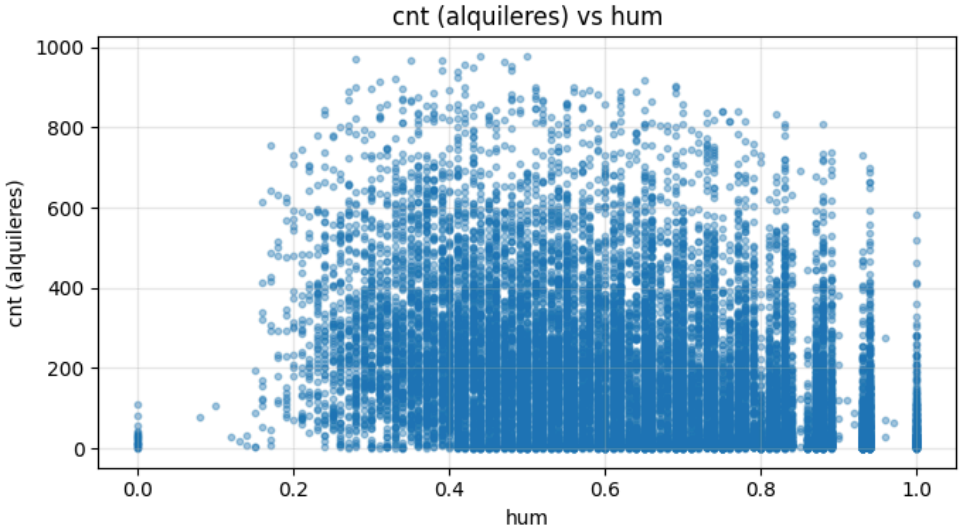
cnt (alquileres) vs hum
cnt (alquileres)
hum
0
200
400
600
800
1000
0.0
0.2
0.4
0.6
0.8
1.0

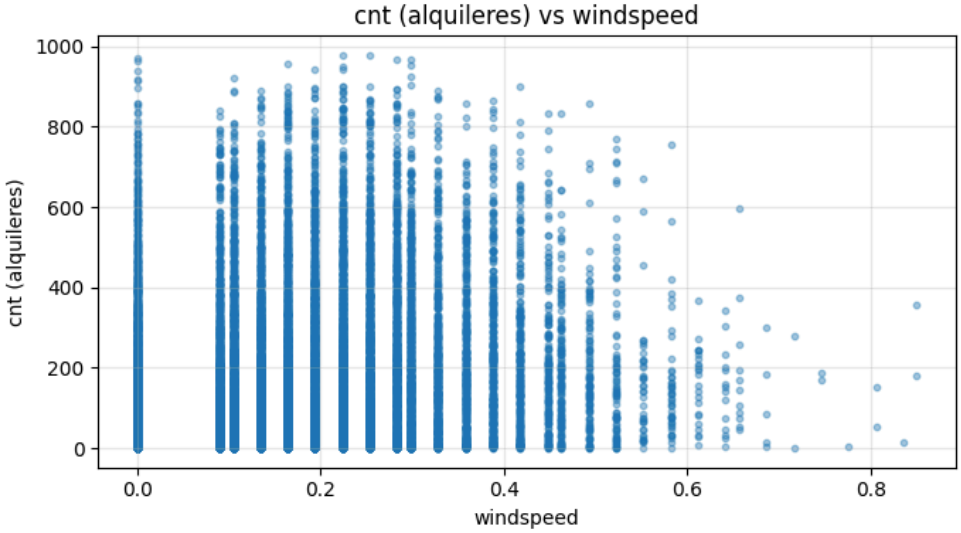
cnt (alquileres) vs windspeed
cnt (alquileres)
windspeed
0
200
400
600
800
1000
0.0
0.2
0.4
0.6
0.8

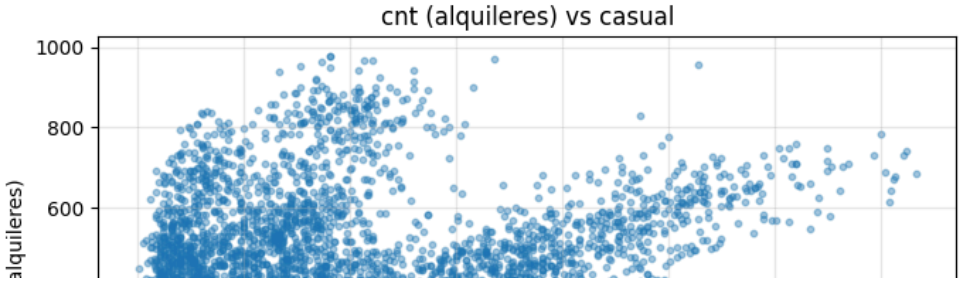
cnt (alquileres) vs casual
600
800
1000

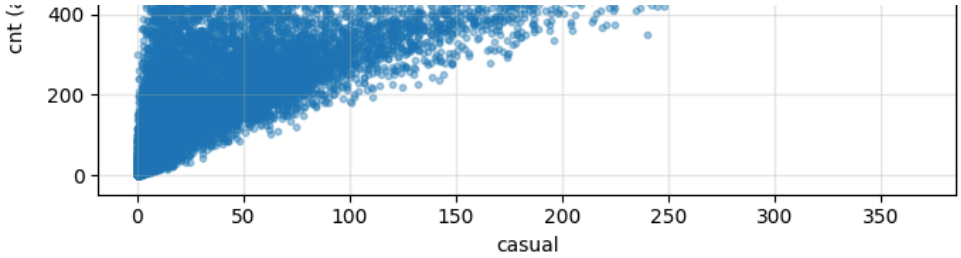

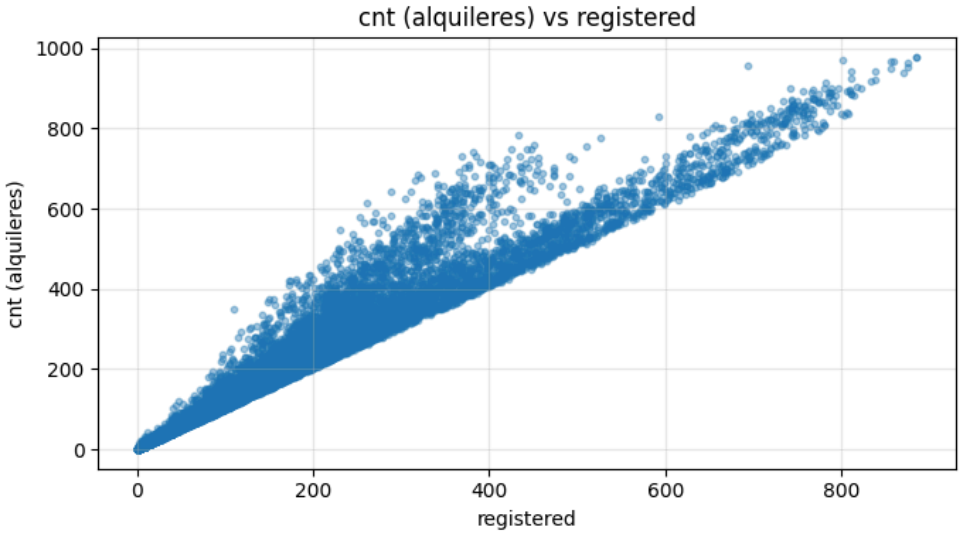

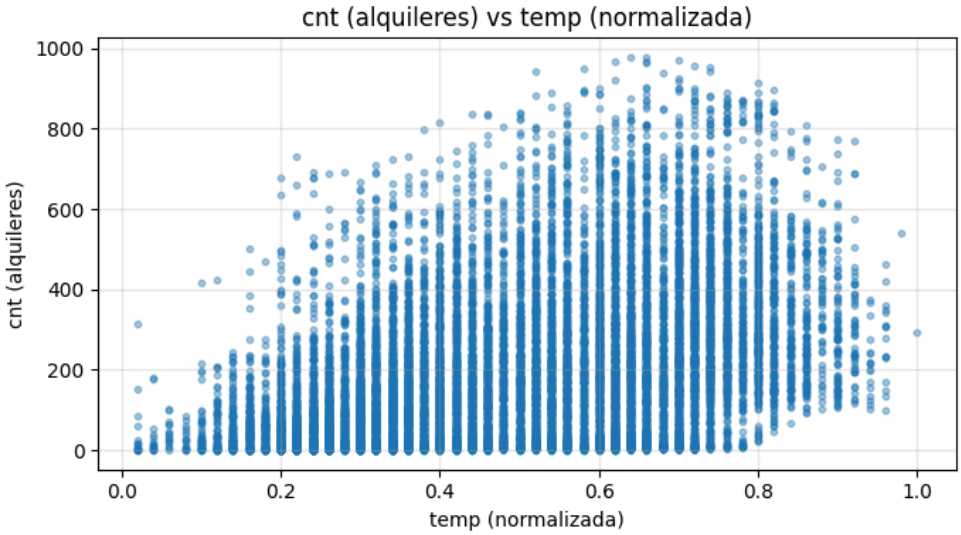

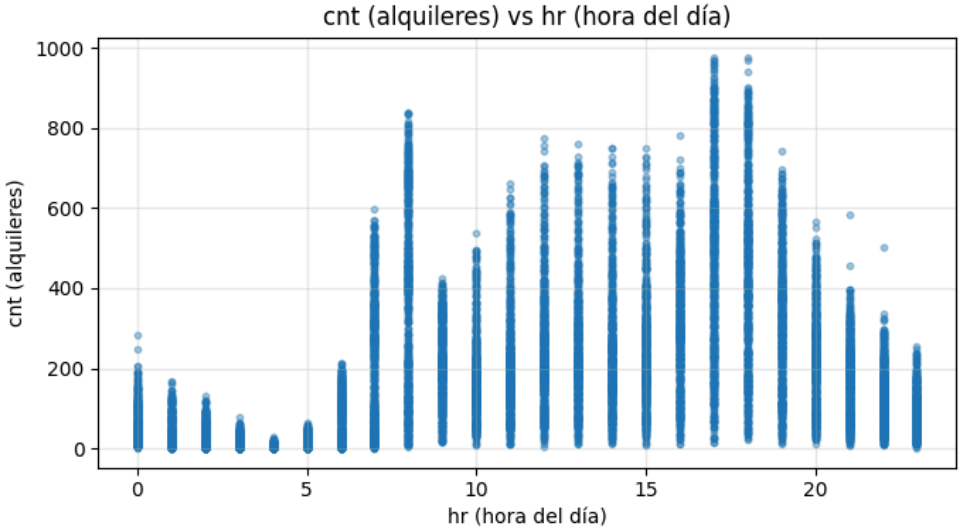


```
=== Correlación (Pearson) — top con cnt ===
```

```
cnt           1.000000
registered    0.972151
casual        0.694564
temp          0.404772
atemp         0.400929
hr            0.394071
instant       0.278379
yr            0.250495
season        0.178056
mnth          0.120638
windspeed     0.093234
workingday    0.030284
weekday       0.026900
holiday      -0.030927
weathersit   -0.142426
hum          -0.322911
Name: cnt, dtype: float64

=== Correlación (Spearman) — top con cnt ===
cnt           1.000000
registered    0.989444
casual        0.850525
hr            0.510878
temp          0.423330
atemp         0.423258
instant       0.243742
yr            0.207500
season        0.185179
windspeed     0.126629
mnth          0.125889
weekday       0.030297
workingday    0.021033
holiday      -0.029526
weathersit   -0.126276
hum          -0.359614
Name: cnt, dtype: float64
```

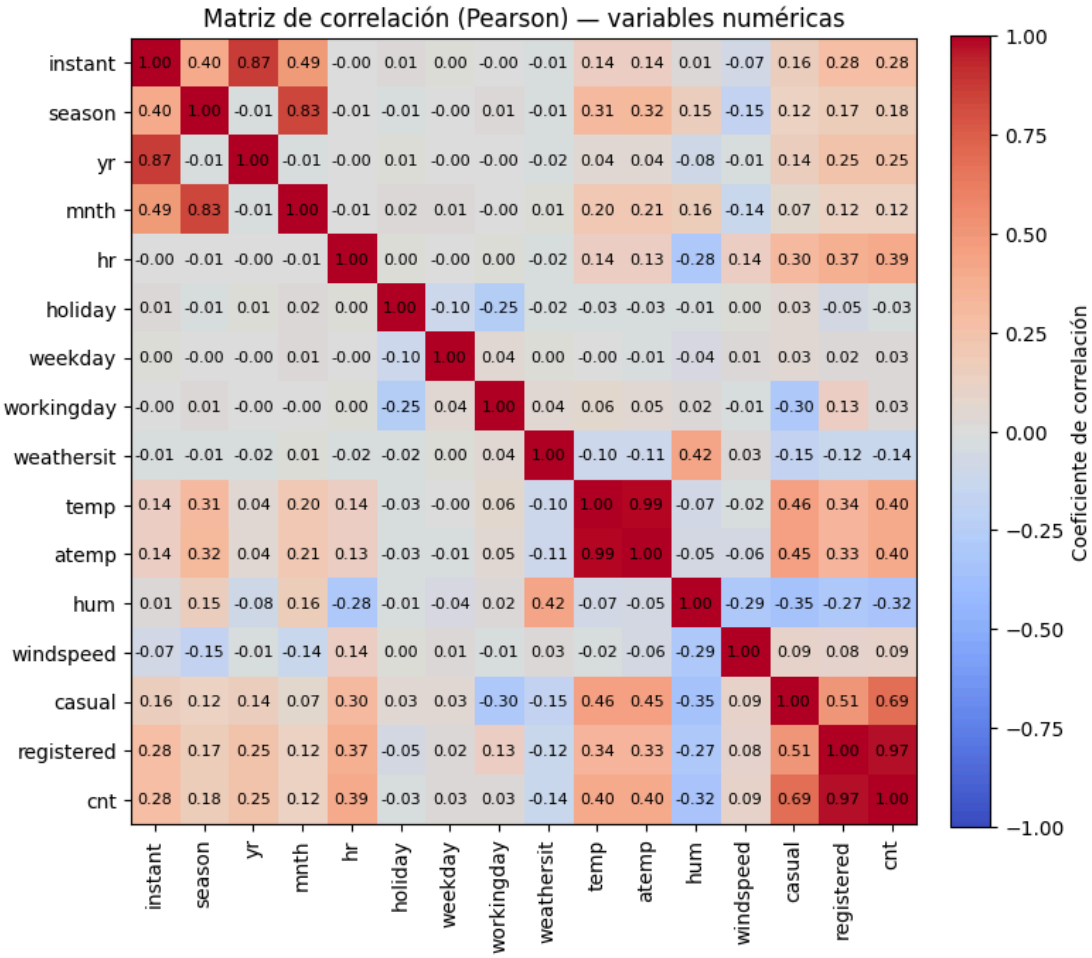

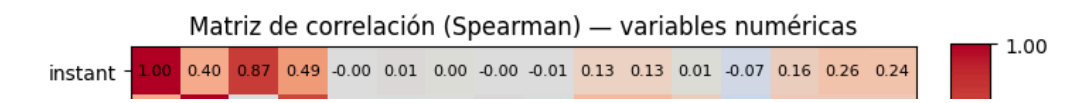

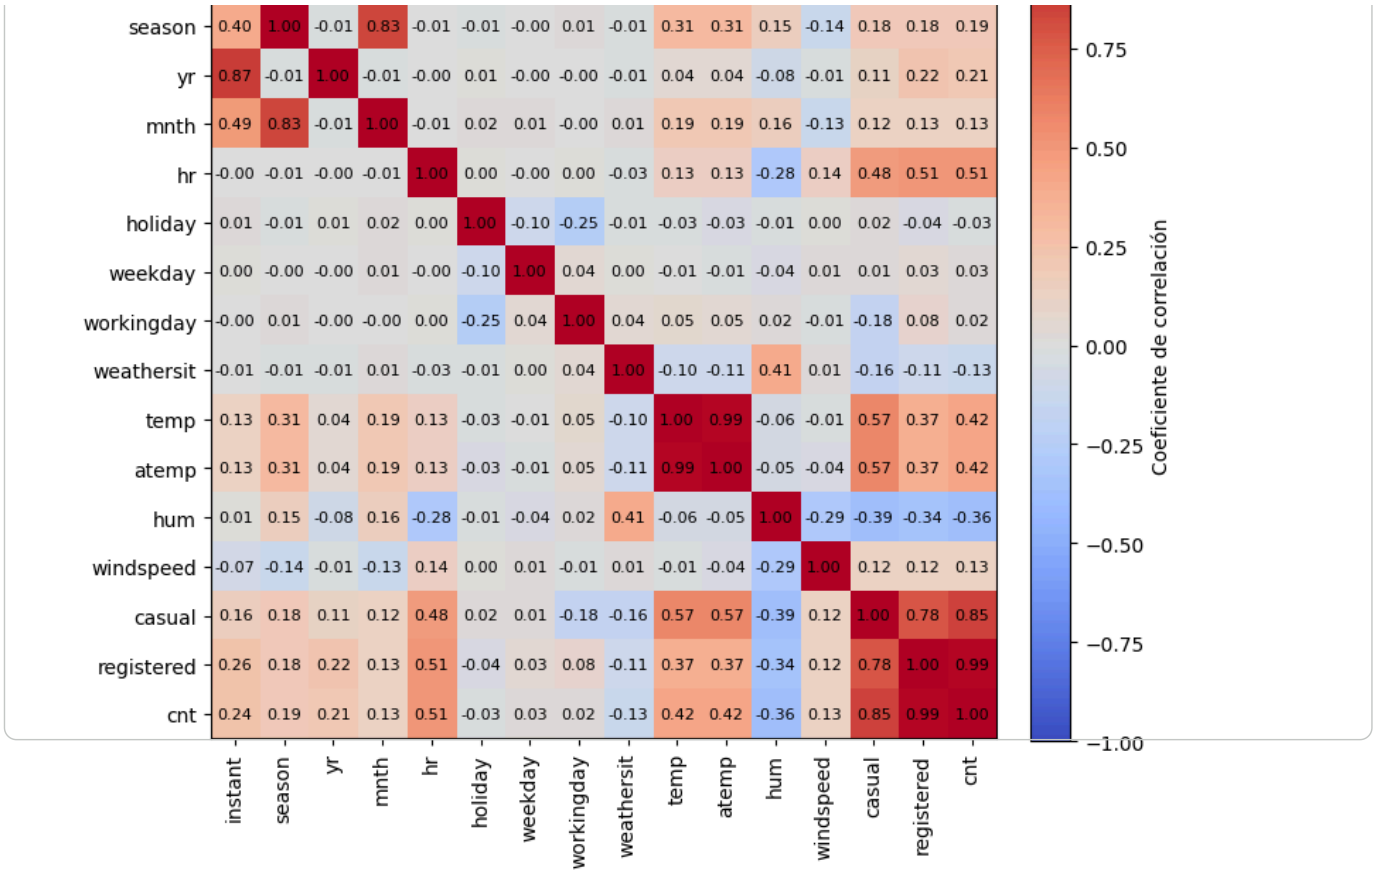

Distribución de registros por season

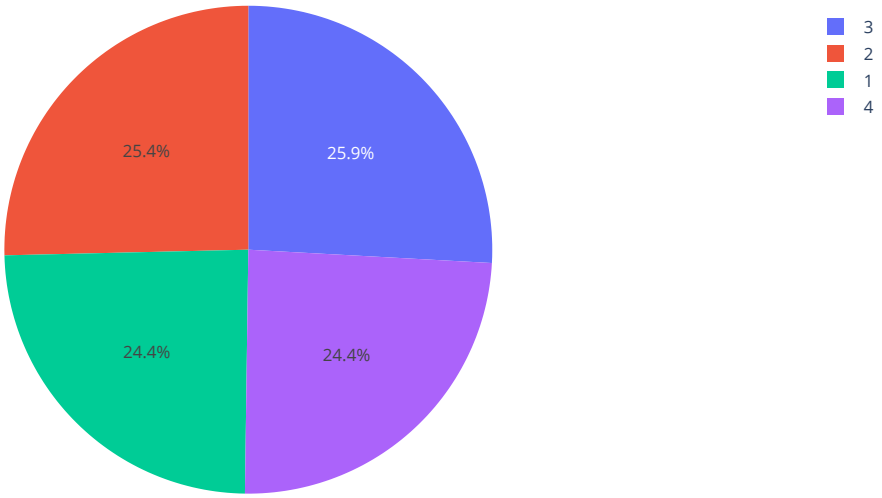

Sunburst de cnt por season y weathersit (suma)

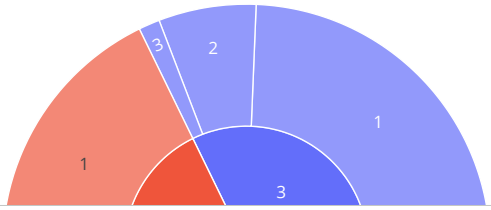

🧹 Limpieza y preparación — Bike Sharing (UCI)

Primero validamos **consistencia y tipos**:

`dteday` debe ser fecha; `season`, `weathersit`, `weekday`, `holiday`, `workingday` son **categóricas codificadas como números** (no continuas) y se tratarán como tales. Verificamos rangos razonables en `temp`, `atemp`, `hum`, `windspeed` (0–1 normalizados) y que `cnt = casual + registered` se cumpla; si no, corregimos o anotamos el caso y lo excluimos del modelado. También buscamos **duplicados** exactos por clave temporal (día u hora) y los removemos si no son intencionales.

Para **errores y valores atípicos**:

revisamos picos imposibles (p. ej., `windspeed=0` con tormenta severa) y fechas fuera de rango. Los outliers operativos se abordan según su origen: si son reales (eventos/feriados), se mantienen; si son errores, se **capan** (winsorizing) o se corrigen con reglas simples documentadas. Evitamos transformar la variable objetivo sin justificación; si la distribución de `cnt` es muy asimétrica, se puede evaluar una **transformación log(1+cnt)** solo si mejora la interpretación y la métrica.

El **tratamiento de datos faltantes** depende del patrón: si el porcentaje es bajo y aleatorio, usamos **imputación simple** (mediana en numéricas, categoría "desconocido" en categóricas). Si los faltantes se concentran en ciertos periodos o categorías, mejor es **eliminar** esos registros si no compromete la cobertura estacional; de lo contrario, imputar y **marcar con una bandera** ("is_missing") para que el modelo capte el patrón.

La **ingeniería de características** parte de `dteday`:

extraemos **mes (`mnth`), día de la semana (`weekday`)** y, en granularidad horaria, **hora (`hr`)**; añadimos indicadores como **fin de semana** y proximidad a feriados si aporta. Las variables categóricas (`season`, `weathersit`, `weekday`, `holiday`, `workingday`, y `hr` si aplica) se codifican con **One-Hot Encoding** para que los modelos lineales y redes interpreten correctamente sus efectos sin imponer un orden artificial. Evitamos crear variables que miren el futuro (p. ej., promedios que incluyan el propio registro) para **prevenir fuga de información**.

En cuanto a **escalado**, los modelos sensibles a la magnitud (Perceptrón/Adaline y MLP) requieren **estandarización** de las variables numéricas; Regresión Lineal también se beneficia al mejorar estabilidad numérica y comparabilidad de coeficientes (si hay regularización). El escalado, la codificación y cualquier imputación deben ir dentro de un **pipeline** para que lo mismo que se aprende en `train` se aplique en `valid` de forma consistente.

Finalmente, definimos la **partición de datos** antes de cualquier cálculo de promedios o transformaciones que usen información global. Si trabajamos con datos por hora o día, preferimos **partición temporal** (entrenar en el pasado, validar en el futuro) para evaluar generalización real; si el objetivo es puramente estático, puede usarse un `train/valid` aleatorio con semilla fija, dejando constancia de la elección y su impacto en la interpretación de resultados.

```
# ============================================================
# LIMPIEZA Y PREPARACIÓN (Bike Sharing UCI) — VERSIÓN SENCILLA
# ------------------------------------------------------------
# ¿Qué hace esta celda?
# 1) Valida y copia el DataFrame df.
# 2) Crea features útiles (is_weekend, is_peak_hour).
# 3) Define columnas numéricas y categóricas (sin fuga de información).
# 4) Parte en TRAIN / TEST (aleatorio por defecto; opcional temporal).
# 5) Imputa faltantes (mediana en numéricas, 'desconocido' en categóricas).
# 6) Aplica ONE-HOT a categóricas **entrenando en TRAIN** y alineando TEST.
# 7) Escala solo numéricas con StandardScaler (ajuste en TRAIN; aplica en TEST).
# 8) Imprime un breve resumen de lo obtenido.
# ============================================================

import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler,OneHotEncoder

# ------------------------------
# 0) VALIDACIONES BÁSICAS
# ------------------------------
if 'df' not in globals():
    raise RuntimeError("No encuentro el DataFrame `df`. Corre antes la celda de CARGA DE DATOS.")

data = df.copy()                    # trabajamos sobre copia
```

```
TARGET = "cnt"                     # variable objetivo (total de alquileres)
assert TARGET in data.columns, f"'{TARGET}' no está en las columnas."

IS_HOURLY = 'hr' in data.columns  # granularidad (horaria si existe 'hr')

# Aseguramos que la fecha sea datetime (útil si hacemos split temporal)
if 'dteday' in data.columns and not np.issubdtype(data['dteday'].dtype, np.datetime64):
    data['dteday'] = pd.to_datetime(data['dteday'], errors='coerce')

# ------------------------------
# 1) INGENIERÍA DE CARACTERÍSTICAS SIMPLE (opcional y didáctica)
# ------------------------------
# (a) Fin de semana: weekday (0=dom, ... , 6=sáb) -> 1 si dom/sáb, 0 si no
if 'weekday' in data.columns:
    data['is_weekend'] = data['weekday'].isin([0,6]).astype(int)

# (b) Hora pico (si es horaria): 7-9 y 17-19
if IS_HOURLY and 'hr' in data.columns:
    data['is_peak_hour'] = data['hr'].isin([7,8,9,17,18,19]).astype(int)

# ------------------------------
# 2) DEFINIR QUÉ FEATURES USAR (¡evitamos fuga!)
# ------------------------------
# Evitamos columnas que causarían fuga o no aportan:
#  - 'casual' y 'registered' suman el target --> NO usarlas como features
#  - 'instant' es solo un índice
#  - 'dteday' (fecha cruda) no la modelamos directa; si quieres mes/semana, derivar antes
exclude = {'instant', 'casual', 'registered', TARGET}

# Numéricas continuas típicas del dataset (normalizadas [0,1])
num_cols = [c for c in ['temp','atemp','hum','windspeed'] if c in data.columns]

# Categóricas codificadas como números que trataremos como "categoría"
cat_cols = [c for c in ['season','weathersit','weekday','holiday','workingday','mnth'] if c in data.columns]
if IS_HOURLY and 'hr' in data.columns:
    cat_cols.append('hr')

# Features adicionales que pudimos crear arriba
extra_cols = [c for c in ['is_weekend','is_peak_hour'] if c in data.columns]

# Conjunto final de columnas a usar
feature_cols = [c for c in (num_cols + cat_cols + extra_cols) if c not in exclude]

# X (features) e y (target) antes del split
X_all = data[feature_cols].copy()
y_all = data[TARGET].copy()

# Convertimos las categóricas a tipo category (buena práctica)
for c in cat_cols:
    if c in X_all.columns:
        X_all[c] = X_all[c].astype('category')

# ------------------------------
# 3) PARTICIÓN TRAIN / TEST
# ------------------------------
SPLIT_METHOD = "random"  # "random" (por defecto) o "time" (temporal)
TEST_SIZE = 0.2          # 80% train / 20% test

if SPLIT_METHOD == "time" and 'dteday' in data.columns:
    # Ordenamos por tiempo; los últimos % serán TEST
    order_cols = ['dteday'] + (['hr'] if IS_HOURLY else [])
    sorted_idx = data.sort_values(order_cols).index
    split_point = int(len(sorted_idx) * (1 - TEST_SIZE))
    train_idx, test_idx = sorted_idx[:split_point], sorted_idx[split_point:]
    X_train, X_test = X_all.loc[train_idx].copy(), X_all.loc[test_idx].copy()
    y_train, y_test = y_all.loc[train_idx].copy(), y_all.loc[test_idx].copy()
else:
    # Aleatorio reproducible
    X_train, X_test, y_train, y_test = train_test_split(
        X_all, y_all, test_size=TEST_SIZE, random_state=42, shuffle=True
    )

print(f"[Split] Train: {len(X_train)} | Test: {len(X_test)} | Método: {SPLIT_METHOD}")
```

```
# ------------------------------
# 4) IMPUTACIÓN DE FALTANTES (simple y sin fuga)
# ------------------------------
# Numéricas -> mediana; Categóricas -> 'desconocido'
num_in_train = [c for c in num_cols if c in X_train.columns]
cat_in_train = [c for c in cat_cols if c in X_train.columns]

# Imputación numérica
if num_in_train:
    medians = X_train[num_in_train].median(numeric_only=True)
    X_train[num_in_train] = X_train[num_in_train].fillna(medians)
    X_test[num_in_train]  = X_test[num_in_train].fillna(medians)

# Imputación categórica
for c in cat_in_train:
    X_train[c] = X_train[c].astype('category')
    X_test[c]  = X_test[c].astype('category')
    # agregamos categoría 'desconocido' si hace falta y rellenamos NaN
    if 'desconocido' not in X_train[c].cat.categories:
        X_train[c] = X_train[c].cat.add_categories(['desconocido'])
    if 'desconocido' not in X_test[c].cat.categories:
        X_test[c] = X_test[c].cat.add_categories(['desconocido'])
    X_train[c] = X_train[c].fillna('desconocido')
    X_test[c]  = X_test[c].fillna('desconocido')

# ------------------------------
# 5) ONE-HOT ENCODING (sin fuga de información)
# ------------------------------
# *** ¿Qué es "one-hot"? ***
#   Convertimos cada columna categórica en varias columnas binarias (0/1),
#   una por categoría. Ej: 'season' con valores {1,2,3,4} genera:
#     season_2, season_3, season_4  (si drop_first=True)  -> evita colinealidad
# *** ¿Por qué "sin fuga"? ***
#   - Ajustamos categorías SOLO con TRAIN (get_dummies en TRAIN).
#   - Luego, en TEST reindexamos para tener EXACTAMENTE las mismas columnas;
#     si falta alguna, rellenamos con 0.
X_train_cat = pd.get_dummies(X_train[cat_in_train], drop_first=True) if cat_in_train else pd.DataFrame(index=X_train.ir
X_test_cat  = pd.get_dummies(X_test[cat_in_train],  drop_first=True) if cat_in_train else pd.DataFrame(index=X_test.inc

# Alinear columnas (clave para no introducir fuga / errores de dimensión)
X_test_cat = X_test_cat.reindex(columns=X_train_cat.columns, fill_value=0)

# Concatenamos con las numéricas originales (ya imputadas)
X_train_num = X_train[num_in_train].copy()
X_test_num  = X_test[num_in_train].copy()

X_train_pre = pd.concat([X_train_num, X_train_cat], axis=1)
X_test_pre  = pd.concat([X_test_num,  X_test_cat],  axis=1)

# ------------------------------
# 6) ESCALADO DE NUMÉRICAS (opcional pero recomendado para MLP/Perceptrón)
# ------------------------------
# Usamos StandardScaler: media=0, desvío=1
scaler = None
if num_in_train:
    scaler = StandardScaler()
    scaler.fit(X_train_pre[num_in_train])                          # ajusta SOLO con TRAIN
    X_train_pre[num_in_train] = scaler.transform(X_train_pre[num_in_train])
    X_test_pre[num_in_train]  = scaler.transform(X_test_pre[num_in_train])

# ------------------------------
# 7) RESUMEN FINAL
# ------------------------------
print("\n=== RESUMEN DE PREPARACIÓN ===")
print(f"- Numéricas usadas: {num_in_train}")
print(f"- Categóricas usadas (one-hot aplicado): {cat_in_train}")
print(f"- Dimensiones -> X_train_pre: {X_train_pre.shape} | X_test_pre: {X_test_pre.shape}")
print("- Listos para modelar:\n"
      "  * Regresión Lineal (baseline)\n"
      "  * Perceptrón/Adaline/MLP (sensible a escala)\n"
      "  * Árboles/RandomForest/GBM (no requieren escalado)\n")
```

```
[Split] Train: 13903 | Test: 3476 | Método: random

=== RESUMEN DE PREPARACIÓN ===
- Numéricas usadas: ['temp', 'atemp', 'hum', 'windspeed']
- Categóricas usadas (one-hot aplicado): ['season', 'weathersit', 'weekday', 'holiday', 'workingday', 'mnth', 'hr']
- Dimensiones -> X_train_pre: (13903, 59) | X_test_pre: (3476, 59)
- Listos para modelar:
  * Regresión Lineal (baseline)
  * Perceptrón/Adaline/MLP (sensible a escala)
  * Árboles/RandomForest/GBM (no requieren escalado)
```

```
# ============================================================
# VISTA "ANTES vs DESPUÉS" EN UNA PROPORCIÓN DE FILAS
# ------------------------------------------------------------
# Objetivo:
# - Mostrar una muestra (proporción) del dataset ORIGINAL (antes)
#   y de los datos PREPARADOS (después) para comparar.
# - Ver formas (shape), columnas y ejemplos lado a lado.
#
# Requisitos:
# - Haber corrido las celdas anteriores:
#   * CARGA DE DATOS (crea `df`)
#   * LIMPIEZA Y PREPARACIÓN (crea `X_train_pre`, `X_valid_pre`, `y_train`, `y_valid`,
#     y variables auxiliares como `feature_cols`, `target_col`).
# ============================================================

import pandas as pd
import numpy as np

# --------- Validaciones mínimas ---------
needed_vars = ["df", "X_train_pre", "X_test_pre", "y_train", "y_test"]
for v in needed_vars:
    if v not in globals():
        raise RuntimeError(f"Falta la variable `{v}`. Por favor, ejecuta antes las celdas de CARGA y PREPARACIÓN.")

# Parámetros de muestreo (puedes ajustarlos):
FRACTION = 0.02    # proporción de filas a mostrar (2%). Si el dataset es muy grande, reduce.
MIN_ROWS = 10       # al menos estas filas
MAX_ROWS = 40       # como máximo estas filas (para no saturar la vista)
RANDOM_STATE = 42

# --------- Construimos "ANTES" (original) ---------
# Usamos solo columnas relevantes: features + target (si existen)
target_col = 'cnt' if 'target_col' not in globals() else target_col
if 'feature_cols' not in globals():
    # Si no está definida (caso excepcional), intentamos una inferencia simple
    # tomando columnas no prohibidas como features.
    exclude_cols = set(['instant','dteday','casual','registered', target_col])
    # Numéricas y categóricas típicas en Bike Sharing
    candidate_cols = [c for c in df.columns if c not in exclude_cols]
    feature_cols_view = candidate_cols
else:
    feature_cols_view = feature_cols

cols_before = [c for c in feature_cols_view if c in df.columns] + ([target_col] if target_col in df.columns else [])
df_before = df[cols_before].copy()

# --------- Construimos "DESPUÉS" (preparado) ---------
# Unimos X_train_pre y y_train (lo mismo para valid) para mostrar ejemplos.
train_prepared = X_train_pre.copy()
train_prepared[target_col] = y_train.values

valid_prepared = X_test_pre.copy()
valid_prepared[target_col] = y_test.values

# Concatenamos train+valid preparados para una vista global "después"
df_after = pd.concat([train_prepared.assign(_split="train"),
                      valid_prepared.assign(_split="valid")], axis=0, ignore_index=True)

# --------- Muestreos controlados (misma cantidad antes y después) ---------
def choose_n_rows(total_len, frac, min_rows, max_rows):
```

```
    n = int(np.ceil(total_len * frac))
    n = max(min_rows, n)
    n = min(max_rows, n)
    n = min(n, total_len)  # no exceder el total
    return n

n_before = choose_n_rows(len(df_before), FRACTION, MIN_ROWS, MAX_ROWS)
n_after  = choose_n_rows(len(df_after), FRACTION, MIN_ROWS, MAX_ROWS)

sample_before = df_before.sample(n=n_before, random_state=RANDOM_STATE)
sample_after  = df_after.sample(n=n_after, random_state=RANDOM_STATE)

# --------- Reporte de formas y columnas ---------
print("=== FORMAS (shape) ===")
print(f"ANTES  (original) -> filas: {df_before.shape[0]}, columnas: {df_before.shape[1]}")
print(f"DESPUÉS (preparado) -> filas: {df_after.shape[0]}, columnas: {df_after.shape[1]}")
print("\n=== Columnas ANTES (primeras 20) ===")
print(list(df_before.columns)[:20], "... (total:", len(df_before.columns), ")")
print("\n=== Columnas DESPUÉS (primeras 20) ===")
print(list(df_after.columns)[:20], "... (total:", len(df_after.columns), ")")

# Nota didáctica:
print("\nNOTA: 'DESPUÉS' suele tener MÁS columnas por el One-Hot Encoding de categóricas,")
print("y las numéricas pueden estar escaladas (media≈0, desvío≈1) si aplicaste estandarización.")
print("La columna '_split' indica si la fila proviene de train o valid.")

# --------- Mostramos las muestras (proporciones) ---------
# Para no saturar, mostramos como tablas; en Colab se ven bonitos.
try:
    from caas_jupyter_tools import display_dataframe_to_user
    display_dataframe_to_user("ANTES (muestra del dataset original)", sample_before.reset_index(drop=True))
    display_dataframe_to_user("DESPUÉS (muestra del dataset preparado)", sample_after.reset_index(drop=True))
except Exception as e:
    print("\n=== ANTES (muestra) ===")
    print(sample_before.reset_index(drop=True).to_string(index=False))
    print("\n=== DESPUÉS (muestra) ===")
    print(sample_after.reset_index(drop=True).to_string(index=False))

# --------- (Opcional) Vista comparativa de una MISMA ventana temporal ---------
# Si quieres comparar exactamente el MISMO período antes vs después, puedes
# filtrar por fecha (y hora si aplica) y luego mostrar esas filas.
DO_SIDE_BY_SIDE_BY_DATE = False  # cambia a True si quieres esta comparación

if DO_SIDE_BY_SIDE_BY_DATE and 'dteday' in df.columns:
    # Elegimos un rango pequeño de fechas
    dmin, dmax = df['dteday'].min(), df['dteday'].max()
    # Tomamos 3 días equiespaciados (ejemplo)
    sample_dates = pd.to_datetime(pd.date_range(dmin, dmax, periods=3)).date
    print("\n=== Comparación por fechas específicas (demostración) ===")
    print("Fechas elegidas:", sample_dates)

    # Filtramos ANTES
    before_mask = df['dteday'].dt.date.isin(sample_dates)
    side_before = df_before.loc[before_mask].copy()

    # Para DESPUÉS, si hiciste split temporal, no siempre es trivial volver a 'dteday'
    # porque después del one-hot/escala podrías haber perdido la columna fecha.
    # Por eso, esta vista es opcional y depende de que conserves 'dteday' como referencia
    # en alguna estructura paralela. Aquí solo mostramos el "ANTES" filtrado.
    try:
        display_dataframe_to_user("ANTES (rango de fechas elegido)", side_before.reset_index(drop=True))
    except:
        print(side_before.reset_index(drop=True).to_string(index=False))
```

```
=== FORMAS (shape) ===
ANTES  (original) -> filas: 17379, columnas: 12
DESPUÉS (preparado) -> filas: 17379, columnas: 61

=== Columnas ANTES (primeras 20) ===
['temp', 'atemp', 'hum', 'windspeed', 'season', 'weathersit', 'weekday', 'holiday', 'workingday', 'mnth', 'hr', 'cnt']

=== Columnas DESPUÉS (primeras 20) ===
```

```
['temp', 'atemp', 'hum', 'windspeed', 'season_2', 'season_3', 'season_4', 'season_desconocido', 'weathersit_2', 'weath

NOTA: 'DESPUÉS' suele tener MÁS columnas por el One-Hot Encoding de categóricas,
y las numéricas pueden estar escaladas (media≈0, desvío≈1) si aplicaste estandarización.
La columna '_split' indica si la fila proviene de train o valid.

=== ANTES (muestra) ===
 temp  atemp  hum  windspeed  season  weathersit  weekday  holiday  workingday  mnth  hr  cnt
 0.80 0.6970 0.27     0.1940       3           1        6        0           0     6  19  425
 0.24 0.2273 0.41     0.2239       1           1        1        1           0     1  20   88
 0.32 0.3030 0.66     0.2836       4           1        5        0           1    10   2    4
 0.78 0.7121 0.52     0.3582       2           1        2        0           1     5  19  526
 0.26 0.2273 0.56     0.3881       1           1        4        0           1     1   0   13
 0.44 0.4394 0.72     0.2836       1           1        5        0           1     2   0   32
 0.72 0.6667 0.58     0.1343       2           1        4        0           1     5  18  706
 0.26 0.3030 0.87     0.0000       4           1        0        0           0    12   7   26
 0.50 0.4848 0.68     0.1940       1           1        3        0           1     3   2    2
 0.42 0.4242 0.71     0.2239       4           1        3        0           1    10   5   21
 0.18 0.1818 0.55     0.1940       1           1        1        0           1    12   0   34
 0.32 0.3182 0.76     0.1940       2           1        1        0           1     4  22   89
 0.72 0.6515 0.37     0.1045       2           2        6        0           0     6  16  542
 0.54 0.5152 0.77     0.1940       2           2        1        0           1     6   4    9
 0.56 0.5303 0.64     0.1940       3           2        0        0           0     9  17  325
 0.40 0.4091 0.58     0.2985       2           2        2        0           1     3   8  336
 0.12 0.1212 0.50     0.2836       1           2        1        0           1     1   8  188
 0.36 0.3788 0.71     0.0000       4           2        6        0           0    12  14  479
 0.44 0.4394 0.62     0.2537       4           1        0        0           0     9   6   16
 0.66 0.6212 0.31     0.1343       2           1        4        0           1     5  17  852
 0.20 0.2121 0.64     0.1343       1           1        6        0           0     1   3    8
 0.60 0.5758 0.78     0.1343       3           2        1        0           1     8   6  161
 0.42 0.4242 0.88     0.2537       1           3        6        0           0     1  19   37
 0.82 0.8030 0.59     0.0000       3           1        1        0           1     7  10   84
 0.52 0.5000 0.63     0.3284       4           1        4        0           1    12  22  124
 0.36 0.3636 0.76     0.0896       4           1        1        0           1    10   6  144
 0.62 0.5758 0.83     0.0000       2           2        5        0           1     5   2   23
 0.44 0.4394 0.72     0.1343       1           1        4        0           1     1  15  188
 0.16 0.1364 0.47     0.3881       1           2        0        0           0     1   4    6
 0.44 0.4394 0.33     0.2985       4           2        5        0           1    12   6   82
 0.30 0.3182 0.81     0.1045       4           2        3        0           1    10   3    3
 0.66 0.6212 0.65     0.2239       3           1        4        0           1     7   1   29
 0.52 0.5000 0.40     0.3284       2           1        4        0           1     5  20  374
 0.16 0.1515 0.47     0.2239       1           1        6        0           0     1  23   76
 0.66 0.6212 0.69     0.0000       3           1        4        0           1     8   0   76
 0.78 0.7424 0.62     0.1343       3           2        2        0           1     8  17  868
 0.62 0.5455 0.94     0.0896       4           3        2        0           1     9   4    8
 0.38 0.3939 0.58     0.3881       4           1        3        0           1    11  19  122
 0.64 0.6061 0.73     0.2836       2           3        2        0           1     5  21  109
 0.70 0.6515 0.61     0.1940       3           1        3        0           1     8  21  315
```

📌 Método 1 — **Regresión Lineal (baseline)**

La **regresión lineal múltiple** es tu línea base: rápida, interpretable y suficiente cuando la relación entre `X` y `cnt` es aproximadamente **lineal**. Recomendado revisar **residuales**: si muestran curvaturas/patrones, sugiere que falta capturar **no linealidad** o interacciones. Reporta **MAE**, **RMSE** y **R^2**, y comenta brevemente los **coeficientes** más relevantes (signo y magnitud).

```
import numpy as np
import pandas as pd
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

# --- Entrenar ---
lin = LinearRegression()
lin.fit(X_train_pre, y_train)

# --- Predicción y métricas ---
y_tr_pred = lin.predict(X_train_pre)
y_te_pred = lin.predict(X_test_pre)

def rmse(y_true, y_pred):
    return np.sqrt(((y_true - y_pred)**2).mean())

print("== Regresión Lineal (OLS) ==")
print(f"Train -> MAE: {mean_absolute_error(y_train, y_tr_pred):.3f} | "
```

```
      f"RMSE: {rmse(y_train, y_tr_pred):.3f} | R2: {r2_score(y_train, y_tr_pred):.3f}")
print(f"Test  -> MAE: {mean_absolute_error(y_test,  y_te_pred):.3f} | "
      f"RMSE: {rmse(y_test,  y_te_pred):.3f} | R2: {r2_score(y_test,  y_te_pred):.3f}")

# --- Coeficientes con nombres de features ---
feature_names = X_train_pre.columns.to_list()
coefs = pd.Series(lin.coef_, index=feature_names).sort_index(key=lambda s: s.str.lower())

print("\nTop coeficientes por |magnitud|:")
display(coefs.head(len(coefs)))




# --- Fórmula (string) resumida: intercepto + primeros 12 términos ---
terms = [f"{lin.intercept_:.4f}"] + [f"{lin.coef_[i]:+.4f}·{feature_names[i]}" for i in range(len(feature_names))]
formula_short = "cnt_hat = " + " ".join(terms[:13]) + " + …"
print("\nFórmula (resumen):")
print(formula_short)
```

```
== Regresión Lineal (OLS) ==
Train -> MAE: 79.974 | RMSE: 110.403 | R2: 0.633
Test  -> MAE: 77.806 | RMSE: 108.615 | R2: 0.627

Top coeficientes por |magnitud|:
```

	0
atemp	1.586423e+01
holiday_1	-1.614431e+01
holiday_desconocido	-1.065814e-13
hr_1	-1.728650e+01
hr_10	1.060539e+02
hr_11	1.263339e+02
hr_12	1.679785e+02
hr_13	1.614473e+02
hr_14	1.384889e+02
hr_15	1.461936e+02
hr_16	2.139628e+02
hr_17	3.711715e+02
hr_18	3.327259e+02
hr_19	2.284047e+02
hr_2	-2.690822e+01
hr_20	1.541362e+02
hr_21	1.048509e+02
hr_22	6.956264e+01
hr_23	2.973037e+01
hum	-2.198837e+01

```
feature_names = X_train_pre.columns.tolist()

terms = [f"{lin.intercept_:.6f}"] + [
    f"{lin.coef_[i]:+.6f}*{feature_names[i]}"
    for i in range(len(feature_names))
]

lines = []
for i in range(0, len(terms), 6):   # 6 términos por línea
    lines.append(" ".join(terms[i:i+6]))

print("cnt_hat = " + " \\\n           ".join(lines))
```

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

def rmse(y_true, y_pred):
    return np.sqrt(((y_true - y_pred) ** 2).mean())

def plot_pred_vs_actual(y_true, y_pred, title="Predicho vs Real (cnt)"):
    y_true = np.asarray(y_true)
    y_pred = np.asarray(y_pred)

    mae  = mean_absolute_error(y_true, y_pred)
    rmse_v = rmse(y_true, y_pred)
    r2   = r2_score(y_true, y_pred)

    # --- Scatter y = x ---
    plt.figure(figsize=(6.5, 6))
    plt.scatter(y_true, y_pred, s=12, alpha=0.5)
    lims = [
        min(np.min(y_true), np.min(y_pred)),
```

```
            max(np.max(y_true), np.max(y_pred))
        ]
        plt.plot(lims, lims, linestyle="--", linewidth=2)  # línea ideal y=x
        plt.xlim(lims); plt.ylim(lims)
        plt.xlabel("cnt real")
        plt.ylabel("cnt predicho")
        plt.title(f"{title}\nR²={r2:.3f} | MAE={mae:.2f} | RMSE={rmse_v:.2f}")
        plt.grid(True, alpha=0.3)
        plt.tight_layout()
        plt.show()

def plot_residuals(y_true, y_pred, title="Residuales (predicho - real)"):
    y_true = np.asarray(y_true)
    y_pred = np.asarray(y_pred)
    resid = y_pred - y_true

    plt.figure(figsize=(7.5, 4))
    plt.scatter(y_true, resid, s=10, alpha=0.5)
    plt.axhline(0, linestyle="--", linewidth=2)
    plt.xlabel("cnt real")
    plt.ylabel("residual = pred - real")
    plt.title(title)
    plt.grid(True, alpha=0.3)
    plt.tight_layout()
    plt.show()

# --- Usa en TEST ---
plot_pred_vs_actual(y_test, y_te_pred, title="TEST: cnt predicho vs real")
plot_residuals(y_test, y_te_pred, title="TEST: residuales")
```

workingday_descansado [illegible]

dtype: float64

```
Fórmula (resumen):
cnt_hat = 39.8127 +37.9422·temp +15.8642·atemp -21.9884·hum -5.3312·windspeed +33.3032·season_2 +28.0805·season_3 +68.17
```